UNIWERSYTET
EKONOMICZNY
W POZNANIU

Agnieszka Popiel

Aplikacja mobilna jako klasyfikator zmian skórnych oparty na konwolucyjnej sieci neuronowej

Mobile Application as a Skin Lesion Classifier Based on a Convolutional Neural Network

Praca magisterska

Promotor: dr hab. inż. Jarogniew Rykowski, prof. UEP

Kierunek: Informatyka i ekonometria

Specjalność: Informatyka w gospodarce i administracji

Poznań 2026

Spis treści

1 Wstęp **1**

1.1 Motywacja 1

1.2 Cele pracy 1

1.3 Metodyka badawcza 1

1.4 Struktura pracy 1

2 Głębokie uczenie w diagnostyce dermatologicznej **2**

2.1 Wpływ rozwoju sztucznej inteligencji na medycynę 2

2.2 Przegląd wstępnych metod diagnostycznych 4

2.3 Głębokie uczenie w dermatologii 7

2.3.1 Podstawy deep learning 7

2.3.2 Klasyfikacja binarna 12

2.3.3 Klasyfikacja wieloklasowa 13

2.3.4 Rozwiązania mobilne 15

2.4 Wyzwania związane z głębokim uczeniem w dziedzinie dermatologii . . . 16

2.4.1 Stronniczość i ograniczona reprezentatywność 16

2.4.2 Problemy z generalizacją 16

2.4.3 Brak wyjaśnialności modeli 17

2.4.4 Regulacje prawne i odpowiedzialność 18

2.4.5 Problemy społeczne 18

2.4.6 Wyzwania związane z aplikacjami mobilnymi 19

2.5 Podsumowanie 19

3 Propozycja systemu do diagnostyki zmian skórnych **21**

3.1 Dostępne zbiory danych zmian skórnych 21

3.1.1 ISIC 21
3.1.2 HAM10000 21
3.1.3 BCN20000 23
3.1.4 DERM7PT 24
3.1.5 PAD-UFES-20 24
3.1.6 MED-NODE 25
3.1.7 PH2 25
3.1.8 Fitzpatrick17k 25
3.1.9 Dermofit 27
3.2 Dobór zbiorów i opis wybranych zmian skórnych 27
3.2.1 Czerniak - melanoma 29
3.2.2 Zmiany melanocytowe - Nevus 31
3.2.3 Rogowacenie słoneczne - actinic keratosis 31
3.2.4 Łagodne rogowacenie - benign keratosis 31
3.2.5 Rak skóry inny niż czerniak - non-melanoma skin cancer 32
3.2.6 Włókniak twardy - dermatofibroma 32
3.2.7 Zmiany naczyniowe - vascular lesions 32
3.3 Infrastruktura 33
3.4 Zastosowanie 33
3.5 Podsumowanie 33

4 Metodyka badania **34**
4.1 Wstęp 34
4.2 Obróbka danych 34
4.3 Przygotowanie modelu do trenowania 34
4.4 Trenowanie modelu 34
4.5 Podsumowanie 34

5 Wyniki i wnioski **35**
5.1 Podsumowanie 35

6 Podsumowanie **36**

Uwagi do pracy

Rozdział 1

Wstęp

1.1 Motywacja

1.2 Cele pracy

1.3 Metodyka badawcza

1.4 Struktura pracy

Rozdział 2

Głębokie uczenie w diagnostyce dermatologicznej

2.1 Wpływ rozwoju sztucznej inteligencji na medycynę

Dynamiczny rozwój technologii w XXI wieku wraz z rosnącym zapotrzebowaniem pacjentów na efektywne rozwiązania w sektorze opieki zdrowotnej, istotnie wpłynął na transformację współczesnej medycyny w ostatnich latach (Chapman i in., 2015). Takie innowacje jak elektroniczna dokumentacja medyczna, telemedycyna oraz technologie przenośne znacznie usprawniły dostępność i wygodę świadczeń usług zdrowotnych, a przełomowe rozwiązania nanotechnologii i druku 3D zrewolucjonizowały dziedzinę implantologii i inżynierii tkankowej (Haleem i in., 2023; Mahara i in., 2023; Thacharodi i in., 2024).

Szczególne znaczenie w współczesnej medycynie zyskały technologie oparte na sieciach neuronowych i sztucznej inteligencji, ponieważ umożliwiają one przetwarzanie i analizę dużych wolumenów danych klinicznych, często w czasie rzeczywistym. Narzędzia wykorzystujące sztuczną inteligencję w medycynie można podzielić na dwie kategorie - systemy wirtualne oraz fizyczne. Do wirtualnych zastosowań sztucznej inteligencji zalicza się narzędzia monitorujące zdrowie i analizujące dane, natomiast fizyczne zastosowania AI w medycynie obejmują roboty pomagające w rutynowych procedurach chirurgicznych, a także inteligentne protezy sterowane adaptacyjnie (Amisha i in., 2019; Nayak i Kumar Das, 2020).

Wykorzystanie technologii opartych na sztucznej inteligencji jest spójne z paradygmatem P4, czyli medycyny personalizowanej, predyktywnej, prewencyjnej i partycypacyjnej, której celem jest umożliwienie kompleksowego podejścia do tematu zdrowia przez analizę rozległych zbiorów danych. W praktyce oznacza to odejście od reaktywnego modelu opieki zdrowotnej na rzecz modelu proaktywnego, skoncentrowanego na profilaktyce oraz wczesnym wykrywaniu potencjalnych chorób. Stan zdrowia pacjenta w medycynie 4P jest opisywany poprzez spersonalizowaną chmurę szczegółowych danych, takich jak pomiary biochemiczne, ocenę narażenia na czynniki ryzyka (np. stres, zanieczyszczenia) oraz dane genetyczne. Inteligentne technologie medyczne zwiększają autonomię oraz wygodę pacjenta jednocześnie zmniejszając biurokrację i koszty usług medycznych przez ograniczenie dokumentacji automatyzację procesów (Alonso, De La Torre Díez i Zapiraín, 2019; Briganti i Le Moine, 2020; Głos, 2017).

W ciągu ostatniej dekady algorytmy oparte na sztucznej inteligencji, implementowane w całej gamie przenośnych urządzeń, znalazły szerokie zastosowanie w kardiologii, umożliwiając obserwowanie i automatyczną analizę parametrów fizjologicznych oraz rejestrację sygnału elektrokardiograficznego. Zdalne monitorowanie zapisu EKG z wykorzystaniem takich urządzeń jak Fitbit czy Apple Watch 4 jak i aplikacji mobilnych, np. Kardia, umożliwia wczesne wykrywanie migotania przedsionków oraz pomaga zarówno pacjentom oraz lekarzom w dokładniejszej ocenie stanu zdrowia (Amisha i in., 2019; Briganti i Le Moine, 2020; Halcox i in., 2017). Systemy przenośnych urządzeń monitorujących zsynchronizowanych z smartfonem i opartych na analizie AI sprawdziły się również w przypadku endokrynologii, dostarczając stały przepływ informacji na temat poziomu glukozy we krwi pacjentów z cukrzycą, oraz w neurologii w celu wczesnego wykrywania ataków epilepsji (Briganti i Le Moine, 2020).

Modele sztucznej inteligencji znajdują szerokie zastosowanie w diagnostyce, obejmującej między innymi takie techniki jak radiografia rentgenowska, rezonans magnetyczny, endoskopia, ultrasonografia oraz patologia cyfrowa. Podejście to jest określane mianem diagnostyki komputerowo wspomaganej - CADx, czyli *computer-aided diagnosis*. W pulmonologii sztuczna inteligencja jest wykorzystywana do interpretacji wyników badań czynnościowych płuc. Oprogramowanie implementujące AI, zwłaszcza z ekspertyzą pulmonologów, charakteryzuje się wyższą dokładnością diagnostyczną niż samodzielna analiza specjalistów (Das i in., 2023; Topalovic i in., 2019). Konwolucyjne sieci

neuronowe (CNN), czyli modele głębokiego uczenia specjalizujące się w analizie obrazów, sprawdziły się w przypadku wykrywania zapalenia i raka płuc, wirusa COVID-19 oraz innych anomalii na zdjęciach rentgenowskich klatki piersiowej (Hussain i in., 2021; Ismael i Şengür, 2021; Lee, Lee i Kwon, 2023; Rajaraman, Candemir i in., 2018). W dziedzinie gastroenterologii wykorzystano CNN do przetwarzania obrazów z endoskopii i ultrasonografii w celu skutecznego wykrywania takich nieprawidłowości jak refluks żołądkowo-przełykowy i zanikowe zapalenie błony śluzowej żołądka (Briganti i Le Moine, 2020; Yang i Bang, 2019). CADx okazało się również skuteczną metodą w przypadku klasyfikacji komórek zarażonych malarią oraz rozpoznawania choroby zwyrodnieniowej stawu kolanowego (Al-rimy i in., 2023; Rajaraman, Antani i in., 2018). Liczne badania poświęcone zastosowaniu metod sztucznej inteligencji w medycznej diagnostyce obrazowej wskazują na wysoką skuteczność modeli głębokiego uczenia w zadaniach klasyfikacji binarnej oraz wieloklasowej, wykrywania obiektów na zdjęciach oraz ich segmentacji (Elyan i in., 2022). Wynika to z faktu, że systemy wizji komputerowej oparte na sieciach neuronowych uczą się bezpośrednio z obrazów, czego konsekwencją jest identyfikacja skomplikowanych wzorców i zależności często niezauważanych nawet przez doświadczonych lekarzy. Modele te funkcjonują jako systemy typu ”black-box”, co pozwala im zakwalifikować subtelne przypadki chorób i wykryć je w wczesnym stadium, choć z drugiej strony uniemożliwia pełną weryfikację poprawności wyników przez człowieka (Richens i Buchard, 2021).

Szczególnie istotnym zastosowaniem wizji komputerowej w systemach *computer-aided diagnosis* stanowi dermatologia, której problematyki podjęto się w niniejszej pracy. W kolejnych podrozdziałach przeprowadzono analizę porównawczą dotychczasowych metod diagnostycznych w dermatologii z nowoczesnymi metodami diagnostyki z asystą komputerową, opartymi na algorytmach uczenia maszynowego.

2.2 Przegląd wstępnych metod diagnostycznych

Tradycyjnie wstępna diagnostyka w dermatologii obejmuje badanie dermoskopowe lub wideodermoskopowe, polegające na ocenie znamienia w około dziesięciokrotnym powiększeniu. W 1994 roku Stolz wraz z współpracownikami zaproponował algorytm dermoskopowy ABCD, opierający się na wielowymiarowej analizie następujących cech: asy-

metrii (A), nierównych i postrzępionych brzegów (B), zróżnicowania kolorów (C) oraz obecności zmian morfologicznych (D), takich jak kropki, smugi, kuleczki lub sieci pigmentowe. Według innych interpretacji kryterium ”D”dotyczy średnicy zmiany przekraczającej 6 mm. Na podstawie sumy iloczynów stopnia spełnienia poszczególnych kryteriów ABCD oraz ich wag jest obliczany wskaźnik badania dermoskopowego TDS (Total Dermatoscopy Score), stanowiący półilościową miarę znacząco poprawiającą skuteczność diagnostyczną, szczególnie w przypadku osób niebędących dermatologami, takich jak pacjenci. Znamiona o wartości TDS poniżej 4,75 są uznawane za łagodne, w przedziale 4,76-5,45 za podejrzane i wymagającej rutynowej kontroli dermoskopowej, a powyżej 5,45 za wysoce podejrzane w kierunku czerniaka (Nachbar i in., 1994; Rutkowski i in., 2016).

Tabela 2.1. Algorytm ABCD

Kryterium	Liczba punktów do przyznania	Waga
A - asymetria	0 - brak asymetrii w osi X i Y 1 - asymetria w jednej z osi 2 - asymetria w obu osiach	1,3
B - nieregularność granicy zmiany	0 - brak nagłych zakończeń zmiany 1 - nagłe zakończenie w jednym segmencie ... 8 - nagłe zakończenie w ośmiu segmentach	0,1
C - zróżnicowanie kolorów zmiany	1 - jeden kolor 2 - dwa kolory ... 6 - sześć kolorów	0,5
D - elementy strukturalne	1 - jeden element ... 5 - pięć elementów	0,5

Źródło: Opracowanie własne na podstawie (Nachbar i in., 1994)

W 2004 roku rozszerzono tę zasadę o dodatkową cechę ”E”, oznaczającą ewolucję rozmiaru, kształtu, koloru, powierzchni oraz innych objawów, co pozwala uwzględnić dynamiczny charakter nowotworu (Abbasi i in., 2004; Duarte i in., 2021). W literaturze przedstawiono również podobny algorytm CASH - kolor (C), architektura (A), symetria (S), homogeniczność (H) - który rozszerza ABCD o analizę wzorców oraz nie wymaga wag, przez co jest prostszy w użyciu (Henning i in., 2008). W diagnostyce potencjalnie złośliwych zmian skórnych jest również wykorzystywana zasada ”brzydkiego kaczątka”,

polegająca na identyfikacji znamion odbiegających wyglądem od innych typowo łagodnych zmian występujących u pacjenta. Znamiona znacząco różniące się od pozostałych uznaje się za potencjalnie złośliwe, ponieważ znamiona barwnikowe należy oceniać nie tylko na podstawie cech morfologicznych pojedynczej zmiany, ale także je rozpatrywać w kontekście pozostałych znamion pacjenta (Grob i Bonerandi, 1998; Kaminska-Winciorek i Spiewak, 2011). Kolejną metodą wstępnej oceny złośliwości zmiany skórnej jest skala siedmiopunktowa (7PCL) opracowana w latach 80. XX wieku. Znamię klasyfikuje się jako podejrzane, jeżeli obecne są co najmniej trzy z danych cech: zmiana wielkości zmiany, nieregularna pigmentacja, nieregularne brzegi, stan zapalny, swędzenie, średnica większa niż 7 mm, sączenie i strupy. W 1989 udoskonalono metodę siedmiu punktów o wagi, które opracowano na podstawie częstotliwości występowania danych objawów w przypadku czerniaka złośliwego skóry. Dwa punkty są przyznawane dla zmiany wielkości, nieregularnej pigmentacji oraz nieregularnych brzegów, natomiast pozostałe cechy są oceniane na jeden punkt. Wynik większy lub równy trzy stanowi wskazanie do badania histopatologicznego (Congdon i Davis, 2023; MacKie, 1990; Mackie, 1989; Walter i in., 2013). Opracowano również algorytmy o podejściu krokowym, takie jak metoda Menziesa, metoda ”chaosu i wzorów”oraz algorytm TADA. Metoda Menziesa jest szczególnie czuła w wykrywaniu czerniaka i składa się z dwóch etapów. Badanie wstępne polega na ocenie symetrii zmiany oraz jednorodności koloru - jeśli oba kryteria są spełnione, znamię jest uznawane za łagodne. W przeciwnym razie analizuje się cechy typowe dla czerniaka, takie jak niebiesko-białawy welon, liczne brązowe lub niebiesko-szare kropki, pseudopodia i smugi promieniste, odbarwienia bliznopodobne, obwodowo ułożone czarne kropki lub grudki, pięć lub sześć kolorów oraz poszerzona siatka. Spełnienie któregokolwiek z tych kryteriów sugeruje wysokie prawdopodobieństwo czerniaka (Menzies i in., 1996). Metoda ”chaosu i wzorów”opiera się na drzewie decyzyjnym badającym obecność ”chaosu”w zmianie, czyli asymetrie struktury i koloru, a następnie analizowane są wzory charakterystyczne dla czerniaka i pozostałych złośliwych nowotworów (Rosendahl i in., 2012). Skala TADA definiuje algorytm triażowy, którego pierwszy etap polega na badaniu znamienia pod kątem trzech powszechnie występujących nowotworów łagodnych (włókniaka twardego, naczyniaka i rogowacenia łojotokowego). Jeżeli zmiana zostanie zakwalifikowana jako jeden z tych trzech nowotworów, powinna być rutynowo monitorowa, lecz jest wykluczona z dalszej oceny pod kątem złośliwości. W kolejnym kroku

jest oceniana obecność nieuporządkowanego lub asymetrycznego rozmieszczenia kolorów i struktur - ich wystąpienie stanowi wskazanie do biopsji. Jeśli takie cechy nie są obecne, jest sprawdzane sześć dodatkowych cech powszechnie występujących w przypadku czerniaka oraz innych zmian nowotworowych (Rogers i in., 2017).

Badanie dermoskopowe stosowane w połączeniu z algorytmami diagnostycznymi oraz wywiadem z pacjentem, stanowi skuteczną metodę profilaktyki czerniaka ze względu na swoją szybkość, nieinwazyjność oraz możliwość ograniczenia konieczności wykonania biopsji skóry. Dokładność rozpoznań klinicznych dla zmian barwnikowych po zastosowaniu dermoskopii wzrasta o około 30% w porównaniu z badaniem okiem nieuzbrojonym. Należy jednak podkreślić, że algorytmy dermoskopowe wykazują ograniczoną skuteczność w przypadku wykrywania wczesnych czerniaków o średnicy poniżej 5 mm, czerniaków guzkowych i bezbarwnikowych oraz zmian w odrębie owłosionej skóry głowy, dłoni i stóp, twarzy, błon śluzowych jamy ustnej i narządów płciowych (Davis i in., 2020; Kaminska-Winciorek i Spiewak, 2011; Rutkowski i in., 2016; Sonthalia, Yumeen i Kaliyadan, 2025). Dermoskopię cechuje również wysoka zależność od doświadczenia specjalisty, ponieważ wymaga ona zarówno szkoleń jak i użycia metod klinicznych, rozumowania poznawczego, diagnostyki różnicowej i znajomości historii zdrowia pacjenta. Badanie dermoskopowe nie stanowi ostatecznej diagnozy i powinno być połączone z histopatologią, ponieważ umożliwia one jednoznaczne rozstrzygnięcie diagnostyki w przypadkach, w których jest widoczny wyraźny wzorzec dermoskopowy (Sonthalia, Yumeen i Kaliyadan, 2025; Yélamos i in., 2019).

2.3 Głębokie uczenie w dermatologii

2.3.1 Podstawy deep learning

W 2000 roku opracowano pierwszy komputerowy system dermoskopii cyfrowej, klasyfikujący zmiany skórne na podstawie cech charakterystycznych czerniaka opisanych w metodzie ABCD i siedmiu punktów (Gutkowicz-Krusin i in., 2000). Wraz z dynamicznym rozwojem sztucznej inteligencji rozpoczęto badania nad jej zastosowaniem w medycynie, w tym w dermatologii (Goodfellow, Bengio i Courville, 2016). Sztuczna inteligencja (AI, ang. *artificial intelligence*) stanowi szeroką dziedzinę badań dotyczącą zdolności systemów komputerowych do symulowania procesów poznawczych. Uczenie maszynowe

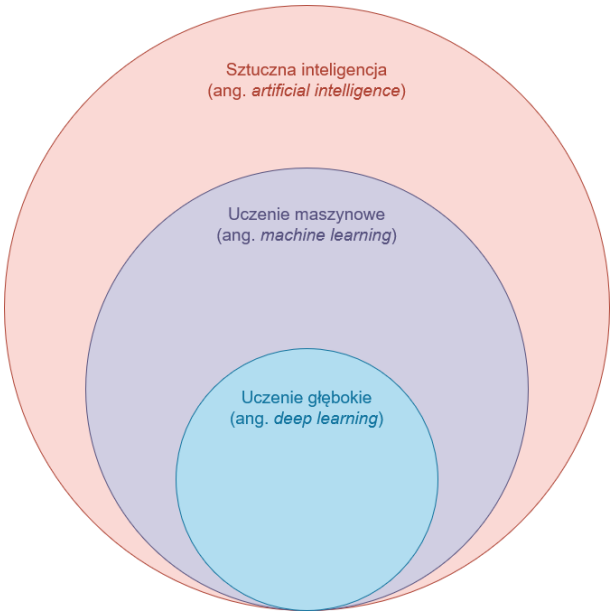

Rysunek 2.1. Relacje między sztuczną inteligencją, uczeniem maszynowym i głębokim uczeniem

Źródło: opracowanie własne

(ML, ang. *machine learning*) jest podzbiorem sztucznej inteligencji poświęconym algorytmom potrafiącym uczyć się z danych oraz identyfikować wzorce bez konieczności dostarczania instrukcji 2.2. Głębokie uczenie (DL, ang. *deep learning*) to obszar uczenia maszynowego polegający na uczeniu głębokich sieci neuronowych, czyli sieci neuronowych składających się z wielu warstw. *Deep learning* radzi sobie szczególnie dobrze z wykrywaniem złożonych struktur i zależności, osiągając przełomowe wyniki zarówno w zadaniach rozpoznawania obrazów i dźwięków jak i rozumienia języka naturalnego i tłumaczeniu (Goodfellow, Bengio i Courville, 2016; LeCun, Bengio i Hinton, 2015; Russell i Norvig, 2022).

Sieci neuronowe (ANN, ang. *artificial neural network*) są definiowane jako systemy przetwarzania informacji inspirowane funkcjonowaniem układu nerwowego. W dziedzinie widzenia komputerowego (CV, *computer vision*) standardem stały się konwolucyjne sieci neuronowe (CNN, ang. *convolutional neural network*), których architektura jest inspirowana korą wzrokową(Ghosh i in., 2020; Hubel i Wiesel, 1968). Podstawy teoretyczne CNN zostały opracowane już w latach 60, lecz ich rozwój rozpoczął się dopiero w 2012 roku wraz z prezentacją architektury AlexNet (Hinton i in., 2012; Hubel i Wiesel, 1968). Tradycyjna konwolucyjna sieć neuronowa 2.2 składa się z jednej lub wielu warstw konwolucyjnych oraz warstw łączenia (ang. *pooling*), po których następuje jedna

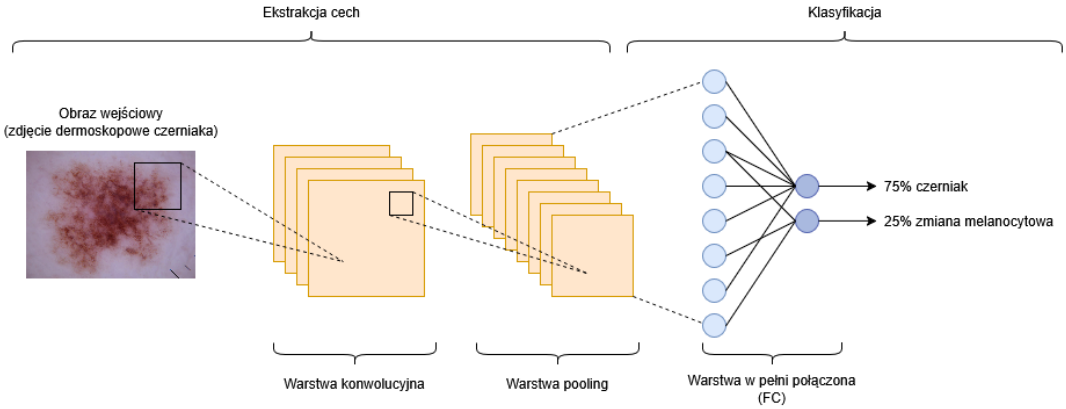

Rysunek 2.2. Podstawowa architektura konwolucyjnej sieci neuronowej

Źródło: opracowanie własne na podstawie (Ghosh i in., 2020)

lub wiele warstw w pełni połączonych (FC, ang. *fully connected*). Warstwa konwolucyjna składa się z kliku jąder konwolucyjnych które obliczają mapy cech danych wejściowych, jednocześnie ucząc się ich reprezentacji. Kolejne warstwy przetwarzają mapy cech z warstw poprzednich, stosując nieliniowe funkcje aktywacji i generując coraz bardziej abstrakcyjne uogólnienia obrazu. Warstwa pooling redukuje liczbę parametrów poprzez zagregowanie danych z poprzednich warstw, natomiast końcowa warstwa FC pełni funkcję klasyfikatora (Ghosh i in., 2020). W efekcie warstwy konwolucyjne najniższych poziomów wykrywają podstawowe cechy, natomiast wyższe warstwy identyfikują bardziej złożone zależności. W przypadku dermoskopowego zdjęcia czerniaka najniższe warstwy przetwarzają podstawowe cechy, takie jak kolor, a kolejne analizują zależności między pojedynczymi pikselami, wykrywając cechy morfologiczne. Następnie warstwa *fully connected* przypisuje prawdopodobieństwo przynależności obrazu do jednej z klas (Ghosh i in., 2020).

W związku z opisanym mechanizmem wiele badaczy analizujących możliwości konwolucyjnych sieci neuronowych w dziedzinach medycznych decyduje się na zastosowanie uczenia transferowego (ang. *transfer learning*). Uczenie transferowe polega na wykorzystaniu wag wstępnie wyszkolonego modelu na dużym, ogólnym zbiorze danych w innym, bardziej wyspecjalizowanym zadaniu, często z mniejszym zbiorem danych. Najczęściej stosowane modele wstępnie wytrenowane to AlexNet, VGGNet, GoogLeNet, DenseNet, EfficientNet oraz ich liczne modele pochodne i mieszane. Technika *transfer learning* jest szeroko wykorzystywana w analizie obrazów medycznych w celu ich segmentacji i klasyfikacji (Ghosh i in., 2020; Mahbod i in., 2020).

Wydajność modeli uczenia maszynowego jest mierzona za pomocą kilku podstawowym metryk. Dokładność (ang. *accuracy*) jest najprostszą miarą określającą zdolność modelu do dokonywania poprawnych przewidywań. Jest stosunkiem liczby poprawnych predykcji do całkowitej liczby przykładów w zbiorze testowym (Erickson i Kitamura, 2021; Grandini, Bagli i Visani, 2020; *Podstawy uczenia maszynowego*, 2022; Rainio, Teuho i Klén, 2024). Dokładność można wyrazić następujących wzorem:

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FP} + \text{TN} + \text{FN}} \tag{2.1}$$

gdzie:

- TP - liczba prawdziwie pozytywnych klasyfikacji,
- TN - liczba prawdziwie negatywnych klasyfikacji,
- FP - liczba fałszywie pozytywnych klasyfikacji,
- FN - liczba fałszywie negatywnych klasyfikacji.

Dokładność nie jest optymalną metryką szczególnie w przypadku zbiorów danych, w których liczebności klas nie są równe. Jeżeli jedna klasa ma znacznie większą liczebność, model może osiągać wysoką dokładność, jednocześnie ignorując rzadkie, lecz kluczowe klinicznie przypadki, takie jak zmiany złośliwe (Grandini, Bagli i Visani, 2020; *Podstawy uczenia maszynowego*, 2022).

W przypadku klasyfikacji wieloklasowej szczególnie przydatna jest macierz pomyłek (ang. *confusion matrix*). Przedstawia ona zestawienie liczby przypadków rzeczywistych i przewidzianych przez model dla każdej z klas, co pozwala ocenić, w jakim stopniu model rozróżnia każdą z klas i z jakimi klasami je myli. Elementy znajdujące się na głównej przekątnej macierzy odpowiadają poprawnym klasyfikacjom. Macierz pomyłek może być normalizowana względem liczby przykładów w klasie, co jest szczególnie przydatne przy niezbalansowanych zbiorach danych (Rainio, Teuho i Klén, 2024).

!!!

jest szczególnie istotna, ponieważ pominięcie przypadku pozytywnego oznacza niewykrycie choroby (*Podstawy uczenia maszynowego*, 2022; Rainio, Teuho i Klén, 2024).

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \tag{2.2}$$

Precyzja (ang. *precision*) określa odsetek prawidłowo sklasyfikowanych pozytywnych przypadków wśród wszystkich predykcji pozytywnych. Wysoka precyzja oznacza, że model ma niską tendencję do klasyfikowania negatywnych przypadków jako pozytywne. Metryka ta jest szczególnie istotna w sytuacjach, w których pomyłki wiążą się z wysokim kosztem (Erickson i Kitamura, 2021; *Podstawy uczenia maszynowego*, 2022; Rainio, Teuho i Klén, 2024).

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \tag{2.3}$$

Zwiększenie precyzji może odbyć się wyłącznie kosztem zmniejszenia pełności, a wzrost pełności spowoduje spadek precyzji, wobec czego jest konieczne znalezienie kompromisu między nimi bądź priorytetyzacja jednej z metryk. W diagnostyce czerniaka złośliwego kluczowa jest pełność, ponieważ koszt konsultacji lub biopsji jest niewielki w porównaniu z ryzykiem przeoczenia zmiany złośliwej (Grandini, Bagli i Visani, 2020; *Podstawy uczenia maszynowego*, 2022; Rainio, Teuho i Klén, 2024).

W badaniach medycznych często stosuje się również swoistość (ang. *specificity*), definiowaną jako odsetek prawidłowo rozpoznanych przypadków negatywnych. Swoistość odzwierciedla zdolność modelu do unikania ”fałszywych alarmów”(Rainio, Teuho i Klén, 2024).

$$\text{Specificity} = \frac{\text{TN}}{\text{TN} + \text{FP}} \tag{2.4}$$

Wynik F1 stanowi średnią harmoniczną z precyzji i pełności. Jest szczególnie przydatny w przypadku niezbalansowanych zbiorów, ponieważ odzwierciedla kompromis między obiema miarami (Erickson i Kitamura, 2021; *Podstawy uczenia maszynowego*, 2022; Rainio, Teuho i Klén, 2024).

$$\text{F1 Score} = \frac{2\text{TP}}{2\text{TP} + \text{FN} + \text{FP}} \tag{2.5}$$

Krzywa charakterystyki operacyjnej odbiornika (ang. *Receiver Operating Characteristic Curve*) przedstawia zależność między odsetkiem prawdziwie pozytywnych i fałszywie pozytywnych klasyfikacji. AUC (ang. *Area Under the Curve*) określa obszar pod krzywą ROC i stanowi miarę jakości klasyfikatora. Wartość AUC równa 0,5 oznacza model działający na poziomie losowego klasyfikatora, 1 świadczy o perfekcyjnym modelu (Erickson i Kitamura, 2021).

W przypadku analizy obejmującej więcej niż dwie klasy, wartości metryk podlegają agregacji na poziomie wszystkich klas. W tym celu stosuje się średnią arytmetyczną (ang. *macro*) lub średnią ważoną (ang. *weighted*). Alternatywnym podejściem jest globalne zliczanie poprawnych i niepoprawnych predykcji (ang. *micro*) albo uśrednienie wyników metryk dla wszystkich próbek (ang. *samples*) (*Podstawy uczenia maszynowego*, 2022).

2.3.2 Klasyfikacja binarna

Bassel i in. (2022) opracowali metodę agregującą wyniki wielu modeli w celu klasyfikacji nowotworów skóry jako złośliwe lub łagodne. Zbiór danych obejmował 1000 obrazów czerniaka i 1000 zdjęć nowotworów łagodnych pochodzących z archiwów ISIC. W badaniu wykorzystano maszynę wektorów nośnych, lasy losowe oraz metodę k-najbliższych sąsiadów, a także głębokie sieci neuronowe takie jak Xception, ResNet50 oraz VGG16. Metoda osiągnęła dokładność 90,9%, wynik F1 równy 89,6%, czułość 88,6% oraz AUC 91,7%.

W 2019 Adegun i Viriri (2020) przedstawili system oparty na głębokich sieciach neuronowych rozróżniający czerniaka od pozostałych zmian skórnych. Model trenowano na zbiorach zdjęć dermoskopowych ISIC 2017 oraz PH2, łącznie obejmujących 2200 obrazów w zbiorze treningowym i 660 w testowym. Autorzy zaproponowali własną architekturę konwolucyjnej sieci neuronowej typu koder-dekoder oraz zastosowali techniki augmentacji obrazu, takie jak losowe obroty. Metoda osiągnęła dokładność 95%, czułość 97% i swoistość 96%.

Alzubaidi i in. (2021) zaproponowali rozwiązanie oparte na głębokich konwolucyjnych sieciach neuronowych, wykorzystuujące zbiory ISIC z konkursów z lat 2016-2020, 170 obrazów z zbioru MED-NODE oraz 1300 zdjęć z zbioru Dermofit. Zastosowali augmentację danych zwiększającą liczbę przykładów do 200 000 oraz techniki transfer lear-

ning oraz double transfer learning. W badaniu uzyskano dokładność wynoszącą 98,57%, pełność 97,9%, precyzję 99,18% oraz F1 równe 98,53%.

Jojoa Acosta i in. (2021) przedstawili architekturę składającą się z dwóch konwolucyjnych sieciach neuronowych. Pierwsza generowała maskę obszaru istotnego (ang. *region of interest*), natomiast druga była oparta na architekturze ResNet152 i klasyfikowała zmiany jako łagodne i złośliwe. Wykorzystano dane z konkursu ISIC z 2017 roku oraz dodatkowo dane ze zbioru PH2, zastosowano technikę *downsampling* dla klasy łagodnej, czyli zmniejszono liczbę przykładów z tej klasy, oraz technikę augmentacji danych. Najlepszy model osiągnął czułość 82%, swoistość 92,5%, dokładność 90,4%.

Menegola i in. (2017) przeanalizowali działanie głębokich sieci neuronowych w połączeniu z różnymi metodami *transfer learning*. Autorzy wykorzystali zbiór Interactive Atlas of Dermoscopy oraz dane z konkursu ISIC 2017. Przetestowano modele ImageNet, VGG-M i VGG-16, wykazując, że *fine-tuning* znacząco poprawia wyniki klasyfikację, a *transfer learning* jest najbardziej efektywny w przypadku modeli uczonych na danych o wysokim stopniu ogólności, takich jak ImageNet.

2.3.3 Klasyfikacja wieloklasowa

Alwakid i in. (2022) przedstawili trzy etapową technikę polegają na wstępnym poprawieniu jakości obrazu, segmentacji obszaru istotnego a następnie analizy przez zmodyfikowany model ResNet-50. Autorzy wykorzystali zbiór HAM10000 opublikowany przez International Skin Imaging Collaboration, który obejmuje siedem klas: raka podstawnokomórkowego, czerniaka złośliwego, włókniaka twardego, łagodne rogowacenie, zmiany naczyniowe oraz melanocytowe. Opracowana metoda osiągnęła dokładność 86%, precyzję 84%, pełność 86% oraz F1 na poziomie 86%, znacznie przewyższając wyniki wcześniejszych badań.

Mahbod i in. (2020) zbadali wpływu kadrowania obrazów zmian skórnych oraz zastosowania uczenia transferowego na modelach EfficientNetB0, EfficientNetB1 i SeResNeXt-50. Autorzy zaproponowali podejście polegające na łączeniu wyników kliku modeli w jeden system decyzyjny, osiągając rezultaty porównywalne z ówcześnie najlepszymi wynikami modeli w rankingu ISIC dla konkursu z 2018 roku, z którego uzyskano dane.

W 2022 roku Lu i Firoozeh Abolhasani Zadeh (2022) przedstawili usprawniony model oparty na głębokiej sieci neuronowej XceptionNet. Dodatkowo zastosowali funkcje aktywację Swish oraz augmentację obrazów. Model wytrenowano na podstawie danych z zbioru HAM10000. Metoda osiągnęła dokładność 100%, czułość 94,05%, precyzję 97,07% oraz wynik F1 95.53%.

Hosseinzadeh Kassani i Hosseinzadeh Kassani (2019) porównali popularne głębokie konwolucyjne sieci neuronowe Xception, AlexNet, VGGNet oraz ResNet w zadaniu klasyfikacji wieloklasowej zmian skórnych. Wykorzystano zbiór ISIC 2018, który obejmuje 10 015 zdjęć dermoskopowych i siedem kategorii zmian skórnych. Najlepsze wyniki osiągnął model ResNet50 z dokładnością wynoszącą 92,08%, F1 92,74%, precyzją 93,73% i pełnością 92,53%.

Han i in. (2018) dokonali *fine-tuning* na konwolucyjnej sieci neuronowej ResNet-152 w celu klasyfikacji 12 kategorii zmian skórnych - raka podstawnokomórkowego, płaskonabłonkowego i śródnabłonkowego, czerniaka złośliwego, rogowacenia słonecznego i łojotokowego, plam soczewicowatych, włókniaka twardego, ziarniniaka ropnego, naczyniaka, brodawki i znamienia melanocytowego, potocznie nazywanego pieprzykiem. *Fine-tuning* obejmował 19 398 obrazów z zbiorów MED-NODE, Dermofit oraz zdjęć z Uniwersytetów Asan i Hallym oraz obrazów pobranych z różnych internetowych atlasów dermatologicznych. Model osiągnął wyniki porównywalne do 16 dermatologów.

Kawahara, Bentaieb i Hamarneh (2016) w 2016 roku zaprezentowali klasyfikator liniowy wytrenowany na podstawie cech wyodrębnionych z głębokiej sieci konwolucyjnej. Model został wyuczony na zbiorze danych Dermofit i rozróżniał dziesięć kategorii zmian skórnych z większą dokładnością niż ówczesne wyniki innych metod dla tego samego zbioru danych.

Esteva i in. (2017) wytrenowali konwolucyjną sieć neuronową GoogleNetInceptionV3 na 129 450 przykładach obejmujących 2032 jednostek chorobowych i porównali jej wydajność z 21 dermatologami. Szczególnie skupiono się na rozróżnianiu nowotworów keratynocytowych (rak podstawnokomórkowy i płaskonabłonkowy) od łagodnych rogowaceń oraz rozróżnianiu czerniaków złośliwych i znamion melanocytowych. Sieć wykazała się skutecznością na poziomie porównywalnym z dermatologami. Autorzy zasugerowali wykorzystanie tego typu rozwiązań do zapewnienia powszechnego dostępu do opieki diagnostycznej po niższych kosztach przy pomocy urządzeń mobilnych.

2.3.4 Rozwiązania mobilne

W 2019 of Computer Science i in. (2020) przedstawili aplikację mobilną dla systemu Android klasyfikującą zmiany skórne na łagodne i złośliwe. Autorzy zastosowali własny, trzy warstwowy model konwolucyjnej sieci neuronowej, VGG-16 oraz Google Inception V3. Model Inception V3 osiągnął dokładność 81% i czułość 84%. Dane uzyskano z archiwów ISIC a do trenowania wykorzystano 1758 obrazów poddanych technice augmentacji danych. Wytrenowany model Google Inception V3 przekonwertowano na model Tensorflow a następnie zaimportowano do aplikacji androidowej z prostym interfejsem użytkownika.

W aplikacji przedstawionej przez Wibowo, Adhi Hartanto i Wisnu Wirawan (2020) wykorzystano model MobileNet v2, cechujący się niewielkim rozmiarem oraz niskim opóźnieniem, zaprojektowany w celu użycia na systemach mobilnych. Zebrano 640 obrazów z oficjalnej strony International Skin Imaging Collaboration i podzielono na zbiór treningowy, testowy oraz walidacyjny. Skupiono się na dwóch rodzajach zmian skórnych - czerniaku złośliwym oraz rogowaceniu słonecznym, które może się przekształcić w raka płaskonabłonkowego. Wykorzystano technikę *region of interest*. Model przetestowano na fizycznie wydrukowanych zdjęciach zmian skórnych, na zdjęciach na komputerze z dziesięcio-centrymetrowym oddaleniem od kamery oraz na faktycznych zdjęciach skóry z czterokrotnym powiększeniem. Model uzyskał 70% dokładność w zadaniu klasyfikacyjnym ze zdjęć kamerą telefonu i 90% dokładności z zdjęciami ze zbioru.

Kousis i in. (2022) zbadali możliwości jedenastu konwolucyjnych sieci neuronowych w zadaniu klasyfikacji siedmiu zmian skórnych. Dane uzyskano z zbioru HAM10000, który obejmuje 10 000 obrazów zmian skórnych. Najlepsze wyniki osiągnął model DenseNet169 z dokładnością 92,25% i pełnością 93,59%. Autorzy wykorzystali uczenie transferowe oraz augmentację zdjęć. Model przekonwertowano do formatu tensorlite i utworzono aplikację mobilną android, która zbiera również informacje o ekspozycji na UV oraz lokalizacji użytkownika.

Dai i in. (2019) przedstawili aplikację mobilną przeznaczoną dla systemu iOS, wykorzystującą autorską sieć konwolucyjną wytrenowaną na podstawie 10 015 obrazów z zbioru HAM10000. Model został następnie przekonwertowany na format mobilny za pomocą biblioteki Core ML, co umożliwiło dokonanie predykcji w czasie niemal rzeczywistym. Po zrobieniu zdjęcia przez użytkownika aplikacja prezentuje na ekranie telefonu

najbardziej prawdopodobną klasę zmiany skórnej. Autorzy nie opublikowali szczegółowych wyników walidacji ani metryk oceniających skuteczność modelu.

Kong i in. (2021) przeprowadzili analizę aplikacji wykrywających raka skóry dostępnych dla konsumentów przez platformy dystrybucji aplikacji mobilnych takie jak Google Play (aplikacje na systemy Android) oraz App Store (aplikacje na systemy iOS).

!!OPISAĆ RESZTĘ BADAŃ PO DOSTANIU DOSTĘPU!!!!!!!!!!!!!!!!!!!

cyjnego. W praktyce klinicznej zdjęcia zmian skórnych mogą być wykonywane różnymi urządzeniami w różnych warunkach, co może obniżyć skuteczność algorytmu (Kelly i in., 2019). Dodatkowo modele mogą uczyć się cech nieistotnych klinicznie, takich jak włosy lub odbicia światła. W jednym badaniu wykazano, że sztuczna inteligencja traktowała obecność linijki na zdjęciach dermoskopowych jako cechę wskazującą na nowotwór, ponieważ lekarze częściej mierzyli zmiany podejrzane o złośliwość (Esteva i in., 2017). Wiele modeli klasyfikacji zmian skórnych nie uwzględnia istotnych czynników klinicznych, takich jak wiek pacjenta, ekspozycja na promieniowanie UV czy historia nowotworów skóry w rodzinie. Ponadto, obecnie sztuczna inteligencja nie jest w stanie zastosować metody "brzydkiego kaczątka", ponieważ algorytmy nie potrafią jeszcze porównywać wielu znamion u jednego pacjenta, aby określić, które z nich odbiega od jego fenotypu znamionowego.

2.4.3 Brak wyjaśnialności modeli

Modele głębokiego uczenia działają na zasadzie "czarnej skrzynki", co utrudnia w wielu przypadkach uzasadnienie decyzji podjętych przez model. W medycynie jest kluczowe zrozumienie oraz weryfikacja diagnozy, dlatego tworzenie wyjaśnialnej sztucznej inteligencji (XAI, ang.*Explainable Artificial Intelligence*) stanowi poważne wyzwanie w wdrażaniu głębokiego uczenia (Ali i in., 2023; He i in., 2019; Kelly i in., 2019).

2.4.3.1 Prywatność i bezpieczeństwo danych

Skuteczne modele głębokiego uczenia wymagają dużych, wolnych od uprzedzeń i dobrze opisanych zbiorów danych. Ich pozyskiwanie wiąże się jednak z koniecznością ich anonimizacji oraz uzyskania zgody od pacjentów. Dane powinny być przechowywane i wykorzystywane z zachowaniem wysokiego stopnia cyberbezpieczeństwa oraz zgodnie z regulacjami prawnymi dotyczącymi ochrony danych (Farhud i Zokaei, 2021; He i in., 2019). Integracja danych medycznych jest dodatkowo utrudniona przez brak standaryzacji. He i in. (2019) wskazują na potrzebę utworzenia globalnych standardów archiwizacji danych medycznych, analogicznych do standardów obrazowania DICOM (ang. *Digital Imaging and Communications in Medicine*).

2.4.4 Regulacje prawne i odpowiedzialność

Kluczowym krokiem we wprowadzaniu bezpiecznych i efektywnych algorytmów uczenia maszynowego do praktyki medycznej są odpowiednie regulacje i rygorystyczna kontrola jakości (He i in., 2019; Kelly i in., 2019). W Unii Europejskiej szczególne znaczenie ma Ogólne Rozporządzenie o Ochronie Danych oraz rozporządzenie o sztucznej inteligencji "AI Act"(„Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2016/679 z dnia 27 kwietnia 2016 r. w sprawie ochrony osób fizycznych w związku z przetwarzaniem danych osobowych i w sprawie swobodnego przepływu takich danych (RODO)", 2016; „Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2024/1689 z dnia 13 czerwca 2024 r. ustanawiające zharmonizowane przepisy dotyczące sztucznej inteligencji (Akt o sztucznej inteligencji)", 2024). Zgodnie z art. 22 RODO każda osoba ma prawo nie podlegać decyzjom podejmowanym wyłącznie automatycznie oraz ma prawo wymagać wyjaśnienia decyzji podjętych przez algorytm, co na obecnym etapie rozwoju technologii AI jest często niemożliwe (He i in., 2019; „Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2016/679 z dnia 27 kwietnia 2016 r. w sprawie ochrony osób fizycznych w związku z przetwarzaniem danych osobowych i w sprawie swobodnego przepływu takich danych (RODO)", 2016). Rozporządzenie AI Act ma na celu zdefiniowanie sztucznej inteligencji oraz ustanowienie ram prawnych dotyczących tworzenia usług i produktów opartych na AI. Systemy medyczne wykorzystujące sztuczną inteligencję w większości należą do kategorii wysokiego ryzyka, co wiąże się z koniecznością spełnienia wymogów dotyczących zarządzania ryzykiem, jakości danych, nadzoru ludzkiego oraz cyberbezpieczeństwa („Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2024/1689 z dnia 13 czerwca 2024 r. ustanawiające zharmonizowane przepisy dotyczące sztucznej inteligencji (Akt o sztucznej inteligencji)", 2024; Van Kolfschooten i Van Oirschot, 2024).

2.4.5 Problemy społeczne

Wdrożenie AI w medycynie wymaga odpowiedniego wyszkolenia kadry medycznej. Lekarze powinni znać zarówno możliwości jak i ograniczenia technologii głębokiego uczenia, aby móc z niej bezpiecznie korzystać. Badania wykazują, że pacjenci i lekarze obawiają się, że adaptacja sztucznej inteligencji w opiece medycznej będzie skutkować de-

personalizacją medycyny i ograniczeniem roli lekarza w procesie diagnostycznym (Tang, Li i Fantus, 2023).

2.4.6 Wyzwania związane z aplikacjami mobilnymi

W przypadku aplikacji mobilnych dodatkowym problemem jest jakość zdjęć wykonywanych przez użytkowników. Rozmazanie, niewłaściwe oświetlenie lub zbyt małe powiększenie mogą znacząco obniżyć skuteczność modelu i prowadzić do błędnych wyników.

2.5 Podsumowanie

Rozwój sztucznej inteligencji oraz powszechne stosowanie smartfonów stwarzają szansę na transformację diagnostyki i leczenia chorób. Systemy oparte na sieciach neuronowych osiągnęły dojrzałość technologiczną i stały się bardziej niezawodne, często osiągając wyniki porównywalne i lepsze od specjalistów, dzięki czemu część z nich znalazła już zastosowanie w praktyce klinicznej (Li i in., 2022). Na obecnym etapie rozwoju głębokie uczenie posiada ogromny potencjał w diagnostyce obrazowej i potrafi wykrywać subtelne sygnały niewidoczne dla człowieka. Należy jednak podkreślić, że sztuczna inteligencja powinna pełnić funkcję asysty dla lekarzy przez ich odciążenie, redukcję błędów oraz standaryzację decyzji, a nie ich zastępować. Chociaż wiele badań porównuje skuteczność algorytmów uczenia maszynowego ze skutecznością lekarzy, najlepsze rezultaty osiąga się w modelu współpracy, w którym lekarze korzystają z inteligentnych narzędzi jako elementu uzupełniającego proces diagnostyczny (Kelly i in., 2019). Z tego względu wprowadzanie AI do praktyki klinicznej powinno odbywać się wyłącznie pod nadzorem specjalistów, tak aby technologia stanowiła realną pomoc zarówno dla lekarzy, jak i pacjentów (Kelly i in., 2019; Naeem i in., 2020).

Aby możliwe było przełożenie wyników badań na skuteczne wdrożenia kliniczne, konieczne są dalsze prace nad następującymi aspektami modeli głębokiego uczenia:

- interpretowalność modeli - zwiększenie możliwości wyjaśniania decyzji podejmowanych przez sztuczną inteligencję oraz eliminacja czynników zakłócających proces uczenia,
- rozwój regulacji prawnych - dostosowanie przepisów do specyfiki systemów AI stosowanych w medycynie,

- definicja ram etycznych -określenie odpowiedzialności za decyzje oraz roli lekarza i sztucznej inteligencji w procesie leczenia,
- tworzenie niezależnych i reprezentatywnych zbiorów danych - obecne zbiory są ograniczone i stronnicze, szczególnie pod względem płci, fototypów skóry oraz wieku pacjentów,
- poufność danych - zapewnienie bezpiecznej integracji zanonimizowanych danych pochodzących z wielu źródeł.

W wyniku powszechności urządzeń mobilnych medycyna stopniowo przenosi się do wymiaru cyfrowego i internetowego Integracja usług zdrowotnych z aplikacjami mobilnymi może znacząco zwiększyć dostępność opieki, poprawić profilaktykę oraz umożliwić pacjentom bardziej świadome zarządzanie własnym zdrowiem. Rozwijanie narzędzi łączących algorytmy diagnostyczne z intuicyjnymi interfejsami mobilnymi stanowi naturalny kierunek rozwoju współczesnej medycyny cyfrowej (Bourouis i in., 2013; of Computer Science i in., 2020). W niniejszej pracy przedstawiono propozycję systemu integrującego możliwości głębokich sieci neuronowych w diagnostyce zmian skórnych z aplikacją mobilną przeznaczoną dla systemu Android, co stanowi przykład praktycznego wykorzystania głebokiego uczenia w nowoczesnej opiece zdrowotnej.

Rozdział 3

Propozycja systemu do diagnostyki zmian skórnych

3.1 Dostępne zbiory danych zmian skórnych

3.1.1 ISIC

Do rozwoju metod sztucznej inteligencji w dermatologii w istotny sposób przyczyniła się organizacja International Skin Imaging Collaboration (ISIC), której celem jest zwiększenie skuteczności wczesnego wykrywania czerniaka i tym samym zmniejszenie śmiertelności związanej z nowotworami skóry. Od 2016 roku ISIC udostępnia obszerne zbiory obrazów z badań dermoskopowych wraz z danymi klinicznymi i wynikami diagnoz, organizując coroczne konkursy mające na celu doskonalenie algorytmów wizji komputerowej. Archiwa ISIC z lat 2016-2024 odegrały kluczową rolę w rozwoju badań nad wykorzystaniem sztucznej inteligencji w diagnostyce nowotworów skóry, a opracowane przez organizację standardy są powszechnie akceptowane w dziedzinie CADx. Zbiory z konkursów ISIC obejmują głównie obrazy dermoskopowe czerniaków i znamion melanocytowych, jednak w internetowych archiwach dostępne są również fotografie wielu innych rodzajów zmian skórnych (Li i in., 2022).

3.1.2 HAM10000

HAM10000 stanowi jeden z najczęściej wykorzystywanych oficjalnych zbiorów International Skin Imaging Collaboration (Li i in., 2022). Został opracowany w celu zgromadzenia

reprezentatywnej kolekcji najważniejszych kategorii diagnostycznych zmian barwnikowych, ponieważ wcześniejsze zasoby, takie jak archiwa ISIC czy zbiór PH2, były znacznie mniejsze i koncentrowały się głównie na diagnozie czerniaka złośliwego. HAM10000 obejmuje 10 015 obrazów dermoskopowych, z czego diagnoza ponad połowy została potwierdzona badaniem histopatologicznym. Zbiór uwzględnia również dane kliniczne pacjentów takie jak wiek, płeć oraz lokalizacja zmiany. Obrazy zbierano na przestrzeni 20 lat w dwóch ośrodkach - w klinice dermatologicznej Uniwersytetu Medycznego w Wiedniu oraz w gabinecie dermatologicznym Cliffa Rosendahla w Queensland. Austriacka część zbioru obejmuje zmiany u pacjentów często charakteryzujących się dużą liczbą znamion lub z znamionami podejrzanymi w kierunku czerniaka. Z kolei australijski zestaw danych pochodzi od pacjentów zamieszkujących region o wysokiej zapadalności na nowotwory skóry, u których często obserwuje się przewlekłe uszkodzenia skóry spowodowane intensywną ekspozycją na promieniowanie słoneczne, takie jak plamy soczewicowate.

Wyróżniono następujące klasy w zbiorze:

- akiec (actinic keratosis)
- bcc (basal cell carcinoma)
- bkl (benign keratosis)
- df (dermatofibroma)
- nv (melanocytic nevi)
- mel (melanoma)
- vasc (vascular lesion)

Klasa ”akiec”obejmuje rogowacenie słoneczne, raka śródnabłonkowego oraz chorobę Bowena, czyli nieinwazyjne nowotwory, które można leczyć miejscowo bez konieczności wykonywania zabiegów chirurgicznych. Pomimo nieinwazyjności tych nowotworów należy wziąć pod uwagę, że te zmiany mogą przekształcić się w inwazyjnego raka płaskonabłonkowego (ang. *squamous cell carcinoma*), nieuwzględnionego w zbiorze. ”Bcc”dotyczy raka podstawnokomórkowego, czyli powszechną odmianę raka nabłonkowego skóry, który jest wysoko uleczalny, lecz w przypadku braku leczenia rozwija się destrukcyjnie. Kategoria bkl stanowi ogólną klasę obejmującą łagodne rogowacenia skóry, takie jak rogowacenie łojotokowe (ang. *seborrheic keratoses*) i plamki słoneczne oraz rogowacenie podobne do liszaju płaskiego. Zdecydowano się na zgrupowanie tych zmian razem ze względu na podobieństwo pod względem biologicznym. ”Df”obejmuje

dermatofibromę, czyli włókniaka twardego. Jest ona łagodną zmianą skórną, najczęściej powstająca w wyniku reakcji zapalnej na uraz. Klasa nv to znamiona melanocytowe, powszechnie znane jako pieprzyki. Kategoria ”mel”dotyczy czerniaka złośliwego wywodzącego się ze znamion melanocytowych. Znamiona mogą być stwarzać ryzyko rozprzestrzeniania się w organizmie poprzez przenikanie poniżej naskórka do skóry właściwej, co w dermatologii określane jest inwazyjnością. W zbiorze uwzględniono wszystkie odmiany czerniaka, ale wykluczono czerniaka bezbarwnikowego, podpaznokciowego, ocznego oraz błony śluzowej. ”Vasc”dotyczy łagodnych znamion naczyniowych, takich jak naczyniaki wiśniowe, ziarniniaki ropne oraz siniaki, które charakteryzują się czerwonym lub fioletowym kolorem. (Tschandl, Rosendahl i Kittler, 2018).

3.1.3 BCN20000

BCN20000 to oficjalny zbiór ISIC udostępniony w 2024 roku. Autorzy zebrali 18 946 obrazów dermoskopowych z kliniki w Barcelonie wykonanych w latach 2010-2016. Zbiór obejmuje osiem kluczowych kategorii diagnostycznych w dermatologii, skupiając się szczególnie na zmianach w trudnych do zdiagnozowania miejscach, takich jak paznokcie i błony śluzowe, które często są pomijane przez pozostałe zbiory. W BCN20000 uwzględniono również płeć i wiek pacjenta oraz położenie zmiany. Wyróżniono następujące klasy w zbiorze:

- ak (actinic keratosis)
- bcc (basal cell carcinoma)
- bkl (benign keratosis)
- df (dermatofibroma)
- scc (squamous cell carcinoma)
- nv (nevus)
- mel (melanoma)
- vasc (vascular lesion)

W porównaniu z zbiorem HAM10000, BCN20000 obejmuje więcej obrazów oraz dodatkowo uwzględnia raka kolczystokomórkowego (scc) (Hernández-Pérez i in., 2024).

3.1.4 DERM7PT

DERM7PT stanowi zbiór danych służący do oceny skuteczności diagnostyki komputerowej na podstawie 7 punktowej skali oceny zmian skórnych. Zbiór obejmuje 1 011 obrazów dermoskopowych, sklasyfikowanych w pięciu kategoriach oraz dwudziestu szczegółowych diagnozach:

- bcc - basal cell carcinoma
- nev - blue nevus, clark nevus, combined nevus, congenital nevus, dermal nevus, recurrent nevus, reed or spitz nevus
- mel - melanoma, melanoma in situ, melanoma < 0,76 mm, melanoma 0,76 to 1,5 mm, melanoma > 1,5 mm
- misc - dermatofibroma, lentigo, melanosis, miscellaneous, vascular lesion
- sk - seborrheic keratosis

W obrębie klasy ”nev”wyszczególniono liczne typy powszechnych zmian melanocytowych, takich jak znamię błękitne, Clarka, złożone, wrodzone, śródskórne, nawrotowe, Reeda oraz Spitza. Klasa ”mel”obejmuje różne warianty czerniaka, w tym czerniaka in situ (nieinwazyjnego) i trzy podgrupy wydzielone na podstawie średnicy zmiany. Kategoria ”misc”zawiera łagodne zmiany skórne, takie jak włókniak twardy, plamki słoneczne czy melanoza. Dodatkowo wyodrębniono osobne klasy dla rogowacenia łojotokowego (sk) oraz raka podstawnokomórkowego (bcc). Autorzy zbioru przypisali każdej zmianie cechy odpowiadające siedmiopunktowej skali, umożliwiając analizę zarówno klasyfikacyjną, jak i cechową (Kawahara i in., 2019).

3.1.5 PAD-UFES-20

PAD-UFES-20 jest zbiorem obejmującym 2 298 przypadków zmian skórnych wykonanych kamerą smartfonu, co czyni go szczególnie istotnym w kontekście projektowania mobilnych systemów wspomagania diagnostyki dermatologicznej. 58% znamion z zbioru zostało poddanych biopsji. PAD-UFES-20 zawiera sześć kategorii zmian skórnych:

- bcc (basal cell carcinoma)
- scc (squamous cell carcinoma)
- ack (actinic keratosis)

- sek (seborrheic keratosis)
- mel (melanoma)
- nev (nevus)

W ramach klasy ”scc”, czyli raka kolczystokomórkowego uwzględniono również chorobę Bowena, który jest nieinwazyjną postacią tego nowotworu. Zbiór obejmuje również szeroki zakres danych klinicznych pacjentów, takich jak informacje o paleniu, obecności bólu lub krwawienia zmiany, a także dane socjoekonomiczne, takie jak dostęp do bieżącej wody i kanalizacji (Pacheco i in., 2020).

3.1.6 MED-NODE

MED-NODE to zbiór danych obejmujący 170 obrazów klinicznych przedstawiających zmiany melanocytowe, spośród których 70 przypadków stanowi czerniak złośliwych a 100 to łagodne zmiany melanocytowe, powszechnie nazywane pieprzykami. Zdjęcia zostały pozyskane w klinice dermatologii Uniwersytetu Medycznego w Groningen, przy użyciu aparatu cyfrowego (Giotis i in., 2015).

3.1.7 PH2

PH2 jest zbiorem opublikowany w 2013 roku, obejmujący 200 obrazów dermoskopowych. 40 przypadków to potwierdzony histopatologicznie czerniak, pozostałe zdjęcia stanowią łagodne znamiona melanocytowe. W zbiorze zawarto również szczegółowe informacje kliniczne i dermoskopowe, w tym ocenę cech strukturalnych, diagnozę kliniczną i histologiczną. Ze względu na swoją kompletność i dostępność PH2 stanowił podstawowy zestaw referencyjny w badaniach nad algorytmami klasyfikacji zmian skórnych, zanim został zastąpiony przez bardziej obszerne zbiory, takie jak HAM10000 (Mendonca i in., 2013).

3.1.8 Fitzpatrick17k

Fitzpatrick17k składa się z 16 577 obrazów klinicznych pochodzących z dwóch internetowych atlasów dermatologicznych - DermaAmin oraz Atlas Dermatologico. Każde zdjęcie oznaczono etykietami typu skóry według skali Fitzpatricka, klasyfikującej reaktywność

skóry na promieniowanie słoneczne. W zbiorze uwzględniono 114 schorzeń skóry, przy czym liczba obrazów przypadających na jedną jednostkę chorobową wynosi od 53 do 653 przypadków. Główne kategorie schorzeń obecne w zbiorze to:

- inflammatory
- malignant epidermal
- genodermatoses
- benign dermal
- benign epidermal
- malignant melanoma
- benign melanocyte
- malignant cutaneous lymphoma
- malignant dermal

Do kategorii chorób zapalnych należą takie jednostki chorobowe jak łuszczyca i trądzik. Klasa ”malignant epidermal”zawiera złośliwe nowotwory naskórka, na przykład raka podstawnokomórkowego i rogowacenie słoneczne. Grupa genodermatoz uwzględnia choroby dziedziczne skóry, takie jak neurofibromatoza i zespół Ehlersa-Danlosa. W klasie ”benign dermal”i ”benign epidermal”zawarto łagodne zmiany skórne na poziomie naskórka i skóry właściwej, na przykład włokniaka twardego lub ziarniniaka naczyniowego. Kategoria łagodnych znamion melanocytowych uwzględnia różne rodzaje pieprzyków. Kategoria ”malignant dermal”obejmuje mięsaka Kaposiego, czyli nowtwór złośliwy wywołany przez wirusa HHV-8. Autorzy uwzględnili także osobą grupę dla czerniaka złośliwego, która zawiera przypadki nowotworu w różnych stadium choroby oraz dla ziarniniaka grzybiastego, czyli najpowszechniejszego chłoniaka skóry (Bowman, Hogan i Sanusi, 2001; Groh i in., 2021; Schneider i Dittmer, 2017).

Zbiór Fitzpatrick17k odpowiada na istotną lukę w dziedzinie diagnostyki komputerowej, dotyczącą niedostatecznej reprezentacji zróżnicowanych fototypów skóry w dostępnych danych. Co więcej, zbiór rozszerza badane jednostki z znamion do ogólnych dermatologicznych schorzeń, takich jak choroby autoimmunologiczne lub urazy. Jednocześnie zbiór jest ograniczony przez brak jednolitej obróbki obrazów, ponieważ zdjęcia są wykonane w różnych warunkach, co skutkuje zmiennością jakości, co nie jest odpowiednimi warunkami do trenowania modeli uczenia maszynowego. Dodatkowy problem stanowi brak publicznie dostępnego archiwum obrazów. Udostępniono jedynie odno-

śniki do atlasów internetowych, co stwarza ryzyko utraty danych w przypadku usunięcia materiałów źródłowych (Groh i in., 2021).

3.1.9 Dermofit

Dermofit to niepubliczny zbiór opracowany przez Uniwersytet Edynburski, obejmujący 1300 obrazów klinicznych sklasyfikowanych w dziesięciu kategoriach zmian skórnych. Diagnozy zostały potwierdzone przez przez dermatologów i dermopatologów. Do każdego obrazu załączono również maskę segmentacyjną, wyznaczającą obszar zmiany. Dermofit obejmuje następujące klasy:

- actinic keratosis
- basal cell carcinoma
- squamous cell carcinoma
- seborrheic keratosis
- malignant melanoma
- nevus
- intraepithelial carcinoma
- pyogenic granuloma
- haemangioma
- dermatofibroma

Na tle innych zbiorów danych Dermofit wyróżnia się obecnością rzadziej spotykanych kategorii zmian skórnych, takich jak rak śródnabłonkowy, ziarniniak naczyniowy oraz naczyniak krwionośny, co zwiększa jego wartość w badaniach nad klasyfikacją wieloklasową (b.d.; Ballerini i in., 2013)

3.2 Dobór zbiorów i opis wybranych zmian skórnych

Ponieważ zbiory danych obejmują wiele jednostek chorobowych, w celu stworzenia mobilnego systemu identyfikacji szerokiej gamy znamion konieczny jest odpowiedni wybór zbiorów oraz tym samym ujednolicenie klas przed dalszą analizą. Ograniczenie typów znamion rozpoznawanych przez system jest konieczne, ponieważ gdy ich liczba będzie

Tabela 3.1. Zestawienie zbiorów zmian skórnych

Nazwa zbioru	Autorzy	Rok publikacji	Dostępność	Metoda zbierania zdjęć	Liczba obrazów	Liczba klas	% potwierdzony histopatologicznie	Klasy
HAM10000	(Tschandl, Rosendahl i Kittler, 2018)	2018	Dostępny publicznie	Badanie dermoskopowe	10 015	7	53,3%	327 - actinic keratosis 514 - basal cell carcinoma 1099 - benign keratosis 115 - dermatofibroma 1113 - melanoma 6705 - nevus 142 - vascular lesion
BCN20000	(Hernández-Pérez i in., 2024)	2024	Dostępny publicznie	Zdjęcia kliniczne, zdjęcia z przybliżeniem, badanie dermoskopowe	18 946	8	100%	737 - actinic keratosis 2809 - basal cell carcinoma 431 - squamous cell carcinoma 1138 - benign keratosis 124 - dermatofibroma 2857 - melanoma 4206 - nevus 111 - vascular lesion
DERM7PT	(Kawahara i in., 2019)	2019	Dostępny publicznie	Zdjęcia kliniczne, badanie dermoskopowe	1 011	20	Brak informacji	42 - basal cell carcinoma 1 - melanoma 64 - melanoma in situ 102 - melanoma < 0,76 mm 53 - melanoma 0,76–1,5 mm 28 - melanoma > 1,5 mm 28 – blue/clark nevus 13 – combined nevus 17 - congenital nevus 33 – dermal nevus 6 – recurrent nevus 79 – reed/spitz nevus 20 – dermatofibroma 24 – lentigo 16 – melanosis 8 – miscellaneous 29 – vascular lesion 45 – seborrheic keratosis
PAD-UFES-20	(Pacheco i in., 2020)	2020	Dostępny publicznie	Zdjęcia kliniczne wykonane smartfonem	2 298	6	58,4%	730 – actinic keratosis 845 – basal cell carcinoma 192 – squamous cell carcinoma 52 – melanoma 244 – nevus 235 – seborrheic keratosis
MED-NODE	(Giotis i in., 2015)	2015	Dostępny publicznie	Zdjęcia wykonane aparatem cyfrowym	170	2	Brak informacji	70 – melanoma 100 – nevus
PH2	(Mendonca i in., 2013)	2013	Dostępny publicznie	Badanie dermoskopowe	200	2	20,5%	40 – melanoma 160 – nevus
Fitzpatrick17k	(Groh i in., 2021)	2021	Dostępny publicznie	Zdjęcia wykonane w różnych warunkach, z różnych źródeł	16 577	114	Brak informacji	10 886 – inflammatory 1352 – malignant epidermal 1194 – genodermatoses 1067 – benign dermal 931 – benign epidermal 573 – malignant melanoma 236 – benign melanocyte 182 – malignant cutaneous lymphoma 156 – malignant dermal
Dermofit	(b.d.; Ballerini i in., 2013)	2013	Wymaga umowy i opłaty	Zdjęcia wykonane aparatem cyfrowym	1 300	10	Brak informacji	45 – actinic keratosis 239 – basal cell carcinoma 88 – squamous cell carcinoma 78 – intraepithelial carcinoma 65 – dermatofibroma 76 – melanoma 331 – nevus 24 – pyogenic granuloma 96 – haemangioma 257 – seborrheic keratosis

Źródło: Opracowanie własne

zbyt duża, model nie będzie miał wystarczająco przykładów, żeby się uczyć, oraz znacznie wzrośnie jego złożoność algorytmiczna. Dobranie zbyt małej liczby klas zmniejszy przydatność modelu. W ramach projektu zdecydowano się na wykorzystanie zbiorów HAM10000, BCN20000, DERM7PT, ISIC 2020 oraz PAD-UFES-20. HAM10000, BCN20000 oraz ISIC 2020 to oficjalne zbiory International Skin Imaging Collaboration, przez co obejmują one podobne klasy i podobnie je definiują. Podstawę danych stanowią HAM10000, BCN20000 ponieważ zawierają bardzo duże ilości obrazów, a diagnostyka jest wysokiej jakości. ISIC 2020 w większości stanowi klasa "unknown", czyli niezakwalifkowana, lecz zbiór został również uwzględniony w badaniach ponieważ zawiera wiele przykładów rzadziej występujących klas, takich jak plamy soczewicowate (ang. *lentigo*) lub rogowacenie liszajowate (ang. *lichenoid keratosis*). Zbiór PAD-UFES-20 jest istotny w przypadku modelu ponieważ uwzględnia zdjęcia wykonane aparatem telefonu komórkowego, co stanowi faktyczne użycie systemu. Dodatkowo uwzględniono zbiór DERM7PT, ponieważ ze względu na oparcie na skali siedmiopunktowej obejmuje on różne cechy kliniczne i szeroką gamę znamion.

Ponieważ analiza zmian skórnych w projekcie opiera się na podstawie zdjęcia, wykorzystano wyłącznie takie metadane jak obrazy oraz diagnozę. Po połączeniu pięciu zbiorów danych w jeden wyróżniono 45 klas, w tym:

- 11 klas i 16923 obrazów znamion melanocytowych, czyli pieprzyków (ang. *nevus*)
- 8 klas i 4857 obrazów czerniaka (ang. *melanoma*)
- 3 klasy i 4210 obrazów raka podstawnokomórkowego (ang. *basal cell carcinoma*)
- 2 klasy i 2237 obrazów łagodnego rogowacenia (ang. *benign keratosis*)
- 3 klasy i 1794 obrazy rogowacenie słoneczne (ang. *actinic keratosis*)
- 2 klasy i 623 obrazy raka kolczystkomórkowego (ang. *squamous cell carcinoma*)
- 3 klasy i 253 obrazów zmian naczyniowych (ang. *vascular lesions*)
- 3 klasy i 239 obrazów włókniaka twardego (ang. *dermatofibroma*)

3.2.1 Czerniak - melanoma

Klasa czerniaka złośliwego obejmuje czerniaki o różnych odmianach i rozmiarach. Są to złośliwe zmiany wywodzące się ze znamion melanocytowych, które mogą być inwazyjne lub nieinwazyjne (in situ). Jeżeli czerniak zostanie wykryty w wczesnym stadium, można

Tabela 3.2. Wykaz klas w wybranych zbiorach danych

Klasa	HAM10000	PAD-UFES-20	DERM7PT	ISIC 2020	BCN20000
ACK	0	730	0	0	0
AK	0	0	0	0	737
BCC	0	845	0	0	2809
BKL	0	0	0	0	1138
DF	0	0	0	0	124
MEL	0	52	0	0	2857
NEV	0	244	0	0	0
NV	0	0	0	0	4206
SCC	0	192	0	0	431
SEK	0	235	0	0	0
VASC	0	0	0	0	111
akiec	327	0	0	0	0
atypical melanocytic proliferation	0	0	0	1	0
basal cell carcinoma	0	0	42	0	0
bcc	514	0	0	0	0
bkl	1099	0	0	0	0
blue nevus	0	0	28	0	0
cafe-au-lait macule	0	0	0	1	0
clark nevus	0	0	399	0	0
combined nevus	0	0	13	0	0
congenital nevus	0	0	17	0	0
dermal nevus	0	0	33	0	0
dermatofibroma	0	0	20	0	0
df	115	0	0	0	0
lentigo	0	0	24	0	0
lentigo NOS	0	0	0	44	0
lichenoid keratosis	0	0	0	37	0
mel	1113	0	0	0	0
melanoma	0	0	1	584	0
melanoma (0.76 to 1.5 mm)	0	0	53	0	0
melanoma (in situ)	0	0	64	0	0
melanoma (less than 0.76 mm)	0	0	102	0	0
melanoma (more than 1.5 mm)	0	0	28	0	0
melanoma metastasis	0	0	4	0	0
melanosis	0	0	16	0	0
miscellaneous	0	0	8	0	0
nevus	0	0	0	5193	0
nv	6705	0	0	0	0
recurrent nevus	0	0	6	0	0
reed or spitz nevus	0	0	79	0	0
seborrheic keratosis	0	0	45	135	0
solar lentigo	0	0	0	7	0
unknown	0	0	0	27124	0
vasc	142	0	0	0	0
vascular lesion	0	0	29	0	0

go wyleczyć poprzez wycięcie chirurgiczne. Istotnie różnią się od pieprzyków swoją nieregularną strukturą oraz brakiem symetrii (Bourke, Graham-Brown i red. wyd. pol. Andrzej Kaszuba, 2010; Tschandl, Rosendahl i Kittler, 2018).

3.2.2 Zmiany melanocytowe - Nevus

Klasa nevus dotyczy łagodnych znamion melanocytowych, powszechnie nazywanych pieprzykami. Odmiany tej zmiany mogą się znacznie różnić pod względem dermoskopowym, na przykład pod względem koloru, lecz w przeciwieństwie do czerniaka, barwa tych znamion jest jednorodna a struktura jest symetryczna (Bourke, Graham-Brown i red. wyd. pol. Andrzej Kaszuba, 2010; Tschandl, Rosendahl i Kittler, 2018).

3.2.3 Rogowacenie słoneczne - actinic keratosis

Klasa rogowacenia słonecznego to nieninwazyjne odmiany raka płaskonabłonkowego, które można leczyć miejscowo. Klasa obejmuje również raka śródnabłonkowego, inaczej nazywanego chorobą Bowena. W większości zbiorów wyodrębniono osobną klasę dla rogowacenia słonecznego, ponieważ mogą się one przekształcić w inwazyjnego raka płaskonabłonkowego, przez co wymagają stałej obserwacji (Bourke, Graham-Brown i red. wyd. pol. Andrzej Kaszuba, 2010; Tschandl, Rosendahl i Kittler, 2018).

3.2.4 Łagodne rogowacenie - benign keratosis

Ponieważ klasy ”bkl”i ”BKL”są ogólnymi klasami obejmującymi różne rodzaje łagodnego rogowacenia, postanowiono pozostawić je jako ogólną klasę i zaliczyć do niej bardziej szczegółowe klasy zmian skórnych, takie jak konkretne klasy dotyczące rogowacenia łojotokowego (SEK, seborrheic keratosis), rogowacenia liszajowatego (lichenoid keratosis) oraz plamek soczewicowatych (lentigo, lentigo NOS). Takie zgrupowanie wynika z tego, że znamiona tego typu są łagodne i są podobne do siebie pod względem biologicznym. Rogowacenie łojotokowe to często występujące, łagodne zmiany przypominające grudki o nierównej powierzchni. Rogowacenie liszajowate to łagodne zmiany skórne o charakterze zapalnym, często o fioletowawym lub czerwonym kolorze. Plamki soczewicowate to łagodne płaskie i z reguły brązowe zmiany skórne powstające wskutek namnażania melanocytów. Wszystkie z tych zmian nie wymagają leczenia, lecz są czasem usuwane

chirurgicznie ze względów estetycznych (Bourke, Graham-Brown i red. wyd. pol. Andrzej Kaszuba, 2010; Tschandl, Rosendahl i Kittler, 2018).

3.2.5 Rak skóry inny niż czerniak - non-melanoma skin cancer

Stworzono również klasę ”non-melanoma skin cancer”dotyczącą raka skóry nie będącego czerniakiem, czyli raka podstawnokomórkowego skóry (bcc, BCC, basal cell carcinoma) oraz raka kolczystkokomórkowego skóry (SCC). Są to najczęśniej występujące złośliwe zmiany skórne, z reguły pojawiające się na skutek promieniowania UV. Obie zmiany rosna powoli i rzadko dają przerzuty, wobec czego wykryte wystarczająco wcześnie dają bardzo dobre rokowania. Leczenie obu tych zmian polega na ich chirurgicznym wycięciu. Decyzja o uwzględnieniu tych klas w jednej grupie wynikała z ich podobieństw biologicznych, zostały jednak wyróżnione od czerniaka ze względu na ich stopień złośliwości (Bourke, Graham-Brown i red. wyd. pol. Andrzej Kaszuba, 2010; Hernández-Pérez i in., 2024; Tschandl, Rosendahl i Kittler, 2018).

3.2.6 Włókniak twardy - dermatofibroma

Włókniak twardy jest łagodna zmianą nowotworowa, przybierającą postać twardego guzka. Najczęściej jest reakcją zapalną na niewielki uraz. Charakteryzuje się siateczkowatymi liniami na obrzeżach zmiany oraz białej plamki w jej środkowej części, wskazującej na zwłóknienie (Bourke, Graham-Brown i red. wyd. pol. Andrzej Kaszuba, 2010; Hernández-Pérez i in., 2024).

3.2.7 Zmiany naczyniowe - vascular lesions

Znamiona naczyniowe to łagodne zmiany skórne, takie jak naczyniaki wiśniowe i ziarniniaki ropne. Wyróżniają się one charakterystycznym czerwono-fioletowym zabarwieniem, oraz wyraźnie ograniczonymi strukturami (Bourke, Graham-Brown i red. wyd. pol. Andrzej Kaszuba, 2010; Tschandl, Rosendahl i Kittler, 2018).

Tabela 3.3. Ujednolicenie klas

Klasa	Oryginalne klasy
melanoma	mel, MEL, melanoma, melanoma (in situ), melanoma (less than 0.76 mm), melanoma (0.76 to 1.5 mm), melanoma (more than 1.5 mm), melanoma metastasis
nevus	nv, NV, NEV, nevus, clark nevus, blue nevus, combined nevus, congenital nevus, dermal nevus, recurrent nevus, reed or spitz nevus
actinic keratosis	akiec, ACK, AK
benign keratosis	SEK, BKL, bkl, seborrheic keratosis, lichenoid keratosis
non-melanoma skin cancer	bcc, BCC, basal cell carcinoma, SCC
dermatofibroma	df, dermatofibroma, DF
vascular lesions	vasc, vascular lesion

3.3 Infrastruktura

3.4 Zastosowanie

3.5 Podsumowanie

Rozdział 4

Metodyka badania

4.1 Wstęp

4.2 Obróbka danych

4.3 Przygotowanie modelu do trenowania

4.4 Trenowanie modelu

4.5 Podsumowanie

Rozdział 5

Wyniki i wnioski

5.1 Podsumowanie

o co mozna polepszyc prace: - system dostepny tylko na android - rozszerzenie o inne systemy - uwzglednienie danych o pacjencie takich jak wiek, plec, lokalizacja zmiany itd - usuwanie wlosow z zdjec - segmentacja ROI (?) - trenowanie tylko na zdjeciach z telefonu - nie mozna okreslic rozmiaru zmiany - nie mozna porownac zmiany z innymi zmianami pacjenta - grad-CAM - gradient-based localization

może seria zdjęć z wielu ujęć I uśrednianie?

Może kilka zdjęć dzień po dniu?

Trenowanie na elefonie jest słąbe, ale może auto-korekta na podsatwie typu /modelu telefonu – eliminacja wad obiektywu?

Rozdział 6

Podsumowanie

Bibliografia

(b.d.). https://licensing.edinburgh-innovations.ed.ac.uk/product/dermofit-image-library

Abbasi, N. R., Shaw, H. M., Rigel, D. S., Friedman, R. J., McCarthy, W. H., Osman, I., Kopf, A. W., Polsky, D. (2004). Early Diagnosis of Cutaneous Melanoma: Revisiting the ABCD Criteria. *JAMA*, *292*(22), 2771. https://doi.org/10.1001/jama.292.22.2771

Adegun, A. A., Viriri, S. (2020). Deep Learning-Based System for Automatic Melanoma Detection. *IEEE Access*, *8*, 7160–7172. https://doi.org/10.1109/ACCESS.2019.2962812

Ali, S., Abuhmed, T., El-Sappagh, S., Muhammad, K., Alonso-Moral, J. M., Confalonieri, R., Guidotti, R., Del Ser, J., Díaz-Rodríguez, N., Herrera, F. (2023). Explainable Artificial Intelligence (XAI): What we know and what is left to attain Trustworthy Artificial Intelligence. *Information Fusion*, *99*, 101805. https://doi.org/10.1016/j.inffus.2023.101805

Alonso, S. G., De La Torre Díez, I., Zapiraín, B. G. (2019). Predictive, Personalized, Preventive and Participatory (4P) Medicine Applied to Telemedicine and eHealth in the Literature. *Journal of Medical Systems*, *43*(5), 140. https://doi.org/10.1007/s10916-019-1279-4

Al-rimy, B. A. S., Saeed, F., Al-Sarem, M., Albarrak, A. M., Qasem, S. N. (2023). An Adaptive Early Stopping Technique for DenseNet169-Based Knee Osteoarthritis Detection Model. *Diagnostics*, *13*(11), 1903. https://doi.org/10.3390/diagnostics13111903

Alwakid, G., Gouda, W., Humayun, M., Sama, N. U. (2022). Melanoma Detection Using Deep Learning-Based Classifications. *Healthcare*, *10*(12), 2481. https://doi.org/10.3390/healthcare10122481

Alzubaidi, L., Al-Amidie, M., Al-Asadi, A., Humaidi, A. J., Al-Shamma, O., Fadhel, M. A., Zhang, J., Santamaría, J., Duan, Y. (2021). Novel Transfer Learning Approach for Medical Imaging with Limited Labeled Data. *Cancers*, *13*(7), 1590. https://doi.org/10.3390/cancers13071590

Amisha, Malik, P., Pathania, M., Rathaur, V. (2019). Overview of artificial intelligence in medicine. *Journal of Family Medicine and Primary Care*, *8*(7), 2328. https://doi.org/10.4103/jfmpc.jfmpc_440_19

Ballerini, L., Fisher, R., Aldridge, B., Rees, J. (2013, styczeń). A Color and Texture Based Hierarchical K-NN Approach to the Classification of Non-melanoma Skin Lesions. https://doi.org/10.1007/978-94-007-5389-1_4

Bassel, A., Abdulkareem, A. B., Alyasseri, Z. A. A., Sani, N. S., Mohammed, H. J. (2022). Automatic Malignant and Benign Skin Cancer Classification Using a Hybrid Deep Learning Approach. *Diagnostics*, *12*(10). https://doi.org/10.3390/diagnostics12102472

Bourke, J., Graham-Brown, R., red. wyd. pol. Andrzej Kaszuba. (2010). *Dermatologia. Podręcznik i atlas.* Elsevier Urban & Partner.

Bourouis, A., Zerdazi, A., Feham, M., Bouchachia, A. (2013). M-Health: Skin Disease Analysis System Using Smartphone's Camera. *Procedia Computer Science*, *19*, 1116–1120. https://doi.org/10.1016/j.procs.2013.06.157

Bowman, P. H., Hogan, D. J., Sanusi, I. (2001). Mycosis fungoides bullosa: Report of a case and review of the literature. *Journal of the American Academy of Dermatology*, *45*(6), 934–939. https://doi.org/10.1067/mjd.2001.117521

Briganti, G., Le Moine, O. (2020). Artificial Intelligence in Medicine: Today and Tomorrow. *Frontiers in Medicine*, *7*, 27. https://doi.org/10.3389/fmed.2020.00027

Chapman, T., Larsson, E., von Wrycza, P., Dahlman, E., Parkvall, S., Sköld, J. (2015). Chapter 1 - From 3G to 4G: background and motivation of 3G evolution. W T. Chapman, E. Larsson, P. von Wrycza, E. Dahlman, S. Parkvall J. Sköld (Red.), *HSPA Evolution* (s. 3–20). Academic Press. https://doi.org/https://doi.org/10.1016/B978-0-08-099969-2.00001-6

Congdon, N. M., Davis, C. M. (2023). A systematic review of the frequency of features of the seven-point checklist in proven cutaneous melanoma: The importance of

change. *Skin Health and Disease*, *3*(6), e295. https://doi.org/10.1002/ski2.295

Dai, X., Spasić, I., Meyer, B., Chapman, S., Andres, F. (2019). Machine Learning on Mobile: An On-device Inference App for Skin Cancer Detection. *2019 Fourth International Conference on Fog and Mobile Edge Computing (FMEC)*, 301–305. https://doi.org/10.1109/FMEC.2019.8795362

Das, N., Happaerts, S., Gyselinck, I., Staes, M., Derom, E., Brusselle, G., Burgos, F., Contoli, M., Dinh-Xuan, A. T., Franssen, F. M., Gonem, S., Greening, N., Haenebalcke, C., Man, W. D.-C., Moisés, J., Peché, R., Poberezhets, V., Quint, J. K., Steiner, M. C., Vanderhelst, E., Abdo, M., Topalovic, M., Janssens, W. (2023). Collaboration between explainable artificial intelligence and pulmonologists improves the accuracy of pulmonary function test interpretation. *European Respiratory Journal*, *61*(5), 2201720. https://doi.org/10.1183/13993003.01720-2022

Davis, S., Piggott, C., Lyon, C., DeSanto, K. (2020). Effectiveness of dermoscopy in skin cancer diagnosis. *Canadian Family Physician Medecin De Famille Canadien*, *66*(10), 739–740.

Duarte, A. F., Sousa-Pinto, B., Azevedo, L. F., Barros, A. M., Puig, S., Malvehy, J., Haneke, E., Correia, O. (2021). Clinical ABCDE rule for early melanoma detection. *European Journal of Dermatology*, *31*(6), 771–778. https://doi.org/10.1684/ejd.2021.4171

Elyan, E., Vuttipittayamongkol, P., Johnston, P., Martin, K., McPherson, K., Moreno-García, C. F., Jayne, C., Sarker, M. M. K. (2022). Computer vision and machine learning for medical image analysis: recent advances, challenges, and way forward. *Artificial Intelligence Surgery*, *2*(1). https://doi.org/10.20517/ais.2021.15

Erickson, B. J., Kitamura, F. (2021). Magician's Corner: 9. Performance Metrics for Machine Learning Models. *Radiology: Artificial Intelligence*, *3*(3), e200126. https://doi.org/10.1148/ryai.2021200126

Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, *542*(7639), 115–118. https://doi.org/10.1038/nature21056

Farhud, D. D., Zokaei, S. (2021). Ethical Issues of Artificial Intelligence in Medicine and Healthcare. *Iranian Journal of Public Health*, *50*(11), i–v. https://doi.org/10.18502/ijph.v50i11.7600

Ghosh, A., Sufian, A., Sultana, F., Chakrabarti, A., De, D. (2020, styczeń). Fundamental Concepts of Convolutional Neural Network. https://doi.org/10.1007/978-3-030-32644-9_36

Giotis, I., Molders, N., Land, S., Biehl, M., Jonkman, M. F., Petkov, N. (2015). MED-NODE: A computer-assisted melanoma diagnosis system using non-dermoscopic images. *Expert systems with applications*, *42*(19), 6578–6585.

Głos, A. (2017). MEDYCYNA P4 I ANTYNOMIE SAMOWIEDZY. *Filozofia w Praktyce*, *Tom 3*(Artykuł 6).

Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning* [http://www.deeplearningbook.org]. MIT Press.

Grandini, M., Bagli, E., Visani, G. (2020). Metrics for Multi-Class Classification: an Overview. https://doi.org/10.48550/ARXIV.2008.05756

Grob, J. J., Bonerandi, J. J. (1998). The 'Ugly Duckling' Sign: Identification of the Common Characteristics of Nevi in an Individual as a Basis for Melanoma Screening. *Archives of Dermatology*, *134*(1), 103. https://doi.org/10.1001/archderm.134.1.103-a

Groh, M., Harris, C., Soenksen, L., Lau, F., Han, R., Kim, A., Koochek, A., Badri, O. (2021). Evaluating deep neural networks trained on clinical images in dermatology with the fitzpatrick 17k dataset. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 1820–1828.

Gutkowicz-Krusin, D., Elbaum, M., Jacobs, A., Keem, S., Kopf, A. W., Kamino, H., Wang, S., Rubin, P., Rabinovitz, H., Oliviero, M. (2000). Precision of automatic measurements of pigmented skin lesion parameters with a MelaFindTM multispectral digital dermoscope: *Melanoma Research*, *10*(6), 563–570. https://doi.org/10.1097/00008390-200012000-00008

Halcox, J. P., Wareham, K., Cardew, A., Gilmore, M., Barry, J. P., Phillips, C., Gravenor, M. B. (2017). Assessment of Remote Heart Rhythm Sampling Using the AliveCor Heart Monitor to Screen for Atrial Fibrillation: The REHEARSE-AF Study. *Circula-*

tion, *136*(19), 1784–1794. https://doi.org/10.1161/CIRCULATIONAHA.117.030583

Haleem, A., Javaid, M., Singh, R. P., Rab, S., Suman, R. (2023). Applications of nanotechnology in medical field: a brief review. *Global Health Journal*, *7*(2), 70–77. https://doi.org/https://doi.org/10.1016/j.glohj.2023.02.008

Han, S. S., Kim, M. S., Lim, W., Park, G. H., Park, I., Chang, S. E. (2018). Classification of the Clinical Images for Benign and Malignant Cutaneous Tumors Using a Deep Learning Algorithm. *Journal of Investigative Dermatology*, *138*(7), 1529–1538. https://doi.org/10.1016/j.jid.2018.01.028

He, J., Baxter, S. L., Xu, J., Xu, J., Zhou, X., Zhang, K. (2019). The practical implementation of artificial intelligence technologies in medicine. *Nature Medicine*, *25*(1), 30–36. https://doi.org/10.1038/s41591-018-0307-0

Henning, J. S., Stein, J. A., Yeung, J., Dusza, S. W., Marghoob, A. A., Rabinovitz, H. S., Polsky, D., Kopf, A. W. (2008). CASH Algorithm for Dermoscopy Revisited. *Archives of Dermatology*, *144*(4). https://doi.org/10.1001/archderm.144.4.554

Hernández-Pérez, C., Combalia, M., Podlipnik, S., Codella, N. C. F., Rotemberg, V., Halpern, A. C., Reiter, O., Carrera, C., Barreiro, A., Helba, B., Puig, S., Vilaplana, V., Malvehy, J. (2024). BCN20000: Dermoscopic Lesions in the Wild. *Scientific Data*, *11*(1), 641. https://doi.org/10.1038/s41597-024-03387-w

Hinton, G., Krizhevsky, A., Sutskever, I., Rachmad, Y. (2012). ImageNet Classification with Deep Convolutional Neural Networks. *Advances in Neural Information Processing Systems*, 1097–1105. https://doi.org/10.1145/3065386

Hosseinzadeh Kassani, S., Hosseinzadeh Kassani, P. (2019). A comparative study of deep learning architectures on melanoma detection. *Tissue and Cell*, *58*, 76–83. https://doi.org/10.1016/j.tice.2019.04.009

Hubel, D. H., Wiesel, T. N. (1968). Receptive fields and functional architecture of monkey striate cortex. *The Journal of Physiology*, *195*(1), 215–243. https://doi.org/10.1113/jphysiol.1968.sp008455

Hussain, E., Hasan, M., Rahman, M. A., Lee, I., Tamanna, T., Parvez, M. Z. (2021). CoroDet: A deep learning based classification for COVID-19 detection using chest X-ray images. *Chaos, Solitons & Fractals*, *142*, 110495. https://doi.org/10.1016/j.chaos.2020.110495

Ismael, A. M., Şengür, A. (2021). Deep learning approaches for COVID-19 detection based on chest X-ray images. *Expert Systems with Applications*, *164*, 114054. https://doi.org/10.1016/j.eswa.2020.114054

Jojoa Acosta, M. F., Caballero Tovar, L. Y., Garcia-Zapirain, M. B., Percybrooks, W. S. (2021). Melanoma diagnosis using deep learning techniques on dermatoscopic images. *BMC Medical Imaging*, *21*(1), 6. https://doi.org/10.1186/s12880-020-00534-8

Kaminska-Winciorek, G., Spiewak, R. (2011). [Basic dermoscopy of melanocytic lesions for beginners]. *Postępy higieny i medycyny doświadczalnej (Online)*, *65*, 501–8. https://doi.org/10.5604/17322693.955121

Kawahara, J., Bentaieb, A., Hamarneh, G. (2016). Deep features to classify skin lesions, 1397–1400. https://doi.org/10.1109/ISBI.2016.7493528

Kawahara, J., Daneshvar, S., Argenziano, G., Hamarneh, G. (2019). Seven-Point Checklist and Skin Lesion Classification Using Multitask Multimodal Neural Nets. *IEEE Journal of Biomedical and Health Informatics*, *23*(2), 538–546. https://doi.org/10.1109/JBHI.2018.2824327

Kelly, C. J., Karthikesalingam, A., Suleyman, M., Corrado, G., King, D. (2019). Key challenges for delivering clinical impact with artificial intelligence. *BMC Medicine*, *17*(1), 195. https://doi.org/10.1186/s12916-019-1426-2

Kong, F. W., Horsham, C., Ngoo, A., Soyer, H. P., Janda, M. (2021). Review of smartphone mobile applications for skin cancer detection: what are the changes in availability, functionality, and costs to users over time? *International Journal of Dermatology*, *60*(3), 289–308. https://doi.org/10.1111/ijd.15132

Kousis, I., Perikos, I., Hatzilygeroudis, I., Virvou, M. (2022). Deep Learning Methods for Accurate Skin Cancer Recognition and Mobile Application. *Electronics*, *11*(9), 1294. https://doi.org/10.3390/electronics11091294

LeCun, Y., Bengio, Y., Hinton, G. (2015). Deep learning. *Nature*, *521*(7553), 436–444. https://doi.org/10.1038/nature14539

Lee, K. H., Lee, R. W., Kwon, Y. E. (2023). Validation of a Deep Learning Chest X-ray Interpretation Model: Integrating Large-Scale AI and Large Language Models for Comparative Analysis with ChatGPT. *Diagnostics*, *14*(1), 90. https://doi.org/10.3390/diagnostics14010090

Li, Z., Koban, K. C., Schenck, T. L., Giunta, R. E., Li, Q., Sun, Y. (2022). Artificial Intelligence in Dermatology Image Analysis: Current Developments and Future Trends. *Journal of Clinical Medicine*, *11*(22), 6826. https://doi.org/10.3390/jcm11226826

Lu, X., Firoozeh Abolhasani Zadeh, Y. A. (2022). Deep Learning-Based Classification for Melanoma Detection Using XceptionNet (S. Jafarzadeh Ghoushchi, Red.). *Journal of Healthcare Engineering*, *2022*, 1–10. https://doi.org/10.1155/2022/2196096

MacKie, R. M. (1990). Clinical recognition of early invasive malignant melanoma. *BMJ (Clinical research ed.)*, *301*(6759), 1005–1006. https://doi.org/10.1136/bmj.301.6759.1005

Mackie, R. M. (1989). *Malignant melanoma: a guide to early diagnosis*. Duphar Laboratories.

Mahara, G., Tian, C., Xu, X., Wang, W. (2023). Revolutionising health care: Exploring the latest advances in medical sciences. *Journal of Global Health*, *13*, 03042. https://doi.org/10.7189/jogh.13.03042

Mahbod, A., Schaefer, G., Wang, C., Dorffner, G., Ecker, R., Ellinger, I. (2020). Transfer learning using a multi-scale and multi-network ensemble for skin lesion classification. *Computer Methods and Programs in Biomedicine*, *193*, 105475. https://doi.org/10.1016/j.cmpb.2020.105475

Mendonca, T., Ferreira, P. M., Marques, J. S., Marcal, A. R. S., Rozeira, J. (2013). PH2 - A dermoscopic image database for research and benchmarking. *2013 35th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, 5437–5440. https://doi.org/10.1109/EMBC.2013.6610779

Menegola, A., Fornaciali, M., Pires, R., Bittencourt, F. V., Avila, S., Valle, E. (2017). Knowledge Transfer for Melanoma Screening with Deep Learning [arXiv:1703.07479], (arXiv:1703.07479). https://doi.org/10.48550/arXiv.1703.07479

Menzies, S. W., Ingvar, C., Crotty, K. A., McCarthy, W. H. (1996). Frequency and morphologic characteristics of invasive melanomas lacking specific surface microscopic features. *Archives of Dermatology*, *132*(10), 1178–1182.

Nachbar, F., Stolz, W., Merkle, T., Cognetta, A. B., Vogt, T., Landthaler, M., Bilek, P., Braun-Falco, O., Plewig, G. (1994). The ABCD rule of dermatoscopy. *Journal of*

the American Academy of Dermatology, *30*(4), 551–559. https://doi.org/10.1016/S0190-9622(94)70061-3

Naeem, A., Farooq, M. S., Khelifi, A., Abid, A. (2020). Malignant Melanoma Classification Using Deep Learning: Datasets, Performance Measurements, Challenges and Opportunities. *IEEE Access*, *8*, 110575–110597. https://doi.org/10.1109/ACCESS.2020.3001507

Nayak, S., Kumar Das, R. (2020, listopad). Application of Artificial Intelligence (AI) in Prosthetic and Orthotic Rehabilitation. W V. Sezer, S. Öncü P. Boyraz Baykas (Red.), *Service Robotics*. IntechOpen. https://doi.org/10.5772/intechopen.93903

of Computer Science, D., Engineering, O., Ladoke Akintola University of Technology, O. Emuoyibofarhe, J., Ajisafe, D. (2020). Early Skin Cancer Detection Using Deep Convolutional Neural Networks on Mobile Smartphone. *International Journal of Information Engineering and Electronic Business*, *12*(2), 21–27. https://doi.org/10.5815/ijieeb.2020.02.04

Pacheco, A. G., Lima, G. R., Salomão, A. S., Krohling, B., Biral, I. P., De Angelo, G. G., Alves Jr, F. C., Esgario, J. G., Simora, A. C., Castro, P. B., Rodrigues, F. B., Frasson, P. H., Krohling, R. A., Knidel, H., Santos, M. C., Do Espírito Santo, R. B., Macedo, T. L., Canuto, T. R., De Barros, L. F. (2020). PAD-UFES-20: A skin lesion dataset composed of patient data and clinical images collected from smartphones. *Data in Brief*, *32*, 106221. https://doi.org/10.1016/j.dib.2020.106221

Podstawy uczenia maszynowego. (2022). Wydawnictwa AGH.

Rainio, O., Teuho, J., Klén, R. (2024). Evaluation metrics and statistical tests for machine learning. *Scientific Reports*, *14*(1), 6086. https://doi.org/10.1038/s41598-024-56706-x

Rajaraman, S., Antani, S. K., Poostchi, M., Silamut, K., Hossain, M. A., Maude, R. J., Jaeger, S., Thoma, G. R. (2018). Pre-trained convolutional neural networks as feature extractors toward improved malaria parasite detection in thin blood smear images. *PeerJ*, *6*, e4568. https://doi.org/10.7717/peerj.4568

Rajaraman, S., Candemir, S., Kim, I., Thoma, G., Antani, S. (2018). Visualization and Interpretation of Convolutional Neural Network Predictions in Detecting Pneumonia in Pediatric Chest Radiographs. *Applied Sciences (Basel, Switzerland)*, *8*(10), 1715. https://doi.org/10.3390/app8101715

Richens, J. G., Buchard, A. (2021). Artificial Intelligence for Medical Diagnosis. W N. Lidströmer H. Ashrafian (Red.), *Artificial Intelligence in Medicine* (s. 1–21). Springer International Publishing. https://doi.org/10.1007/978-3-030-58080-3_29-1

Rogers, T., Marino, M., Dusza, S. W., Bajaj, S., Marchetti, M. A., Marghoob, A. (2017). Triage amalgamated dermoscopic algorithm (TADA) for skin cancer screening. *Dermatology Practical & Conceptual*, *7*(2), 39–46. https://doi.org/10.5826/dpc.0702a09

Rosendahl, C., Cameron, A., McColl, I., Wilkinson, D. (2012). Dermatoscopy in routine practice - "chaos and clues". *Australian Family Physician*, *41*(7), 482–487.

Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2016/679 z dnia 27 kwietnia 2016 r. w sprawie ochrony osób fizycznych w związku z przetwarzaniem danych osobowych i w sprawie swobodnego przepływu takich danych (RODO) [General Data Protection Regulation (GDPR)]. (2016). https://eur-lex.europa.eu/eli/reg/2016/679/oj

Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2024/1689 z dnia 13 czerwca 2024 r. ustanawiające zharmonizowane przepisy dotyczące sztucznej inteligencji (Akt o sztucznej inteligencji) [Artificial Intelligence Act (AI Act)]. (2024). https://eur-lex.europa.eu/eli/reg/2024/1689/oj

Russell, S. J., Norvig, P. (2022). *Artificial intelligence: a modern approach* (Fourth edition, global edition). Pearson.

Rutkowski, P., J. Wysocki, P., Nasierowska-Guttmejer, A., Fijuth, J., Kalinka-Warzocha, E., Świtaj, T., Jeziorski, A., Szacht, M., Zegarski, W., Wysocki, W. M., Rudnicka, L., Owczarek, W., Krzakowski, M. (2016). Cutaneous melanoma – guidelines for diagnostics and therapy in 2016. *Dermatology Review*, *1*, 1–18. https://doi.org/10.5114/dr.2016.57736

Schneider, J. W., Dittmer, D. P. (2017). Diagnosis and Treatment of Kaposi Sarcoma. *American Journal of Clinical Dermatology*, *18*(4), 529–539. https://doi.org/10.1007/s40257-017-0270-4

Sonthalia, S., Yumeen, S., Kaliyadan, F. (2025). Dermoscopy Overview and Extradiagnostic Applications. W *StatPearls*. StatPearls Publishing. http://www.ncbi.nlm.nih.gov/books/NBK537131/

Tang, L., Li, J., Fantus, S. (2023). Medical artificial intelligence ethics: A systematic review of empirical studies. *DIGITAL HEALTH*, *9*, 20552076231186064. https://doi.org/10.1177/20552076231186064

Thacharodi, A., Singh, P., Meenatchi, R., Tawfeeq Ahmed, Z. H., Kumar, R. R. S., V, N., Kavish, S., Maqbool, M., Hassan, S. (2024). Revolutionizing healthcare and medicine: The impact of modern technologies for a healthier future—A comprehensive review. *Health Care Science*, *3*(5), 329–349. https://doi.org/10.1002/hcs2.115

Topalovic, M., Das, N., Burgel, P.-R., Daenen, M., Derom, E., Haenebalcke, C., Janssen, R., Kerstjens, H. A., Liistro, G., Louis, R., Ninane, V., Pison, C., Schlesser, M., Vercauter, P., Vogelmeier, C. F., Wouters, E., Wynants, J., Janssens, W. (2019). Artificial intelligence outperforms pulmonologists in the interpretation of pulmonary function tests. *European Respiratory Journal*, *53*(4), 1801660. https://doi.org/10.1183/13993003.01660-2018

Tschandl, P., Rosendahl, C., Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, *5*(1), 180161. https://doi.org/10.1038/sdata.2018.161

Van Kolfschooten, H., Van Oirschot, J. (2024). The EU Artificial Intelligence Act (2024): Implications for healthcare. *Health Policy*, *149*, 105152. https://doi.org/10.1016/j.healthpol.2024.105152

Walter, F. M., Prevost, A. T., Vasconcelos, J., Hall, P. N., Burrows, N. P., Morris, H. C., Kinmonth, A. L., Emery, J. D. (2013). Using the 7-point checklist as a diagnostic aid for pigmented skin lesions in general practice: a diagnostic validation study. *The British Journal of General Practice: The Journal of the Royal College of General Practitioners*, *63*(610), e345–353. https://doi.org/10.3399/bjgp13X667213

Ward-Peterson, M., Acuña, J. M., Alkhalifah, M. K., Nasiri, A. M., Al-Akeel, E. S., Alkhaldi, T. M., Dawari, S. A., Aldaham, S. A. (2016). Association Between Race/Ethnicity and Survival of Melanoma Patients in the United States Over 3 Decades: A Secondary Analysis of SEER Data. *Medicine*, *95*(17), e3315. https://doi.org/10.1097/MD.0000000000003315

Wibowo, A., Adhi Hartanto, C., Wisnu Wirawan, P. (2020). Android skin cancer detection and classification based on MobileNet v2 model. *International Journal of Advan-*

ces in Intelligent Informatics, *6*(2), 135. https://doi.org/10.26555/ijain.v6i2.492

Yang, Y. J., Bang, C. S. (2019). Application of artificial intelligence in gastroenterology. *World Journal of Gastroenterology*, *25*(14), 1666–1683. https://doi.org/10.3748/wjg.v25.i14.1666

Yélamos, O., Braun, R. P., Liopyris, K., Wolner, Z. J., Kerl, K., Gerami, P., Marghoob, A. A. (2019). Usefulness of dermoscopy to improve the clinical and histopathologic diagnosis of skin cancers. *Journal of the American Academy of Dermatology*, *80*(2), 365–377. https://doi.org/10.1016/j.jaad.2018.07.072

Spis tabel

2.1 Algorytm ABCD 5

3.1 Zestawienie zbiorów zmian skórnych 28
3.2 Wykaz klas w wybranych zbiorach danych 30
3.3 Ujednolicenie klas 33

Spis rysunków

2.1 Relacje między sztuczną inteligencją, uczeniem maszynowym i głębokim uczeniem 8
2.2 Podstawowa architektura konwolucyjnej sieci neuronowej 9

Spis kodów źródłowych