UNIWERSYTET
EKONOMICZNY
W POZNANIU

Agnieszka Popiel

Aplikacja mobilna jako klasyfikator zmian skórnych oparty na konwolucyjnej sieci neuronowej

Mobile Application as a Skin Lesion Classifier Based on a Convolutional Neural Network

Praca magisterska

Promotor: dr hab. inż. Jarogniew Rykowski

Kierunek: Informatyka i ekonometria

Specjalność: Informatyka w gospodarce i administracji

Poznań 2026

Spis treści

1 Wstęp **1**

1.1 Motywacja 1

1.2 Cele pracy 1

1.3 Metodyka badawcza 1

1.4 Struktura pracy 1

2 Wpływ rozwoju sztucznej inteligencji na medycynę **2**

2.1 Rozwój diagnostyki w dermatologii 2

2.2 Przegląd wstępnych metod diagnostycznych 4

2.3 Głębokie uczenie w dermatologii 7

2.3.1 Podstawy deep learning 7

2.3.2 Klasyfikacja binarna 12

2.3.3 Klasyfikacja wieloklasowa 13

2.3.4 Rozwiązania mobilne 15

2.4 Wyzwania związane z głębokim uczeniem w dziedzinie dermatologii . . . 16

2.4.1 Stronniczość i ograniczona reprezentatywność 16

2.4.2 Problemy z generalizacją 16

2.4.3 Brak wyjaśnialności modeli 17

2.4.4 Regulacje prawne i odpowiedzialność 18

2.4.5 Problemy społeczne 18

2.4.6 Wyzwania związane z aplikacjami mobilnymi 19

2.5 Podsumowanie 19

3 Propozycja systemu do diagnostyki zmian skórnych **21**

3.1 Dostępne zbiory danych zmian skórnych 21

3.1.1 Dobór zbiorów i opis zmian skórnych 21
3.2 Infrastruktura 21
3.3 Zastosowanie 21
3.4 Podsumowanie 21

4 Metodyka badania **22**
4.1 Wstęp 22
4.2 Obróbka danych 22
4.3 Przygotowanie modelu do trenowania 22
4.4 Trenowanie modelu 22
4.5 Podsumowanie 22

5 Wyniki i wnioski **23**
5.1 Podsumowanie 23

6 Podsumowanie **24**

Uwagi do pracy

Rozdział 1

Wstęp

1.1 Motywacja

1.2 Cele pracy

1.3 Metodyka badawcza

1.4 Struktura pracy

Rozdział 2

Głębokie uczenie w diagnostyce dermatologicznej

2.1 Wpływ rozwoju sztucznej inteligencji na medycynę

Dynamiczny rozwój technologii w XXI wieku wraz z rosnącym zapotrzebowaniem pacjentów na efektywne rozwiązania w sektorze opieki zdrowotnej, istotnie wpłynął na transformację współczesnej medycyny w ostatnich dekadach (Chapman i in., 2015). Innowacje takie jak elektroniczna dokumentacja medyczna, telemedycyna oraz technologie przenośne znacznie usprawniły dostępność i wygodę świadczeń usług zdrowotnych, a przełomowe rozwiązania nanotechnologii i druku 3D zrewolucjonizowały dziedzinę implantologii i inżynierii tkankowej (Haleem i in., 2023; Mahara i in., 2023; Thacharodi i in., 2024).

Szczególne znaczenie w współczesnej medycynie zyskały technologie oparte na sieciach neuronowych i sztucznej inteligencji, ponieważ umożliwiają one przetwarzanie i analizę dużych wolumenów danych klinicznych, często w czasie rzeczywistym. Narzędzia wykorzystujące sztuczną inteligencję w medycynie można podzielić na dwie kategorie - systemy wirtualne oraz fizyczne. Do wirtualnych zastosowań sztucznej inteligencji zalicza się narzędzia monitorujące zdrowie i analizujące dane, natomiast fizyczne zastosowania AI w medycynie obejmują roboty wspierające lub wykonujące rutynowe procedury chirurgiczne, a także inteligentne protezy sterowane adaptacyjnie (Amisha i in., 2019; Nayak i Kumar Das, 2020).

Wykorzystanie technologii opartych na sztucznej inteligencji jest spójne z paradygmatem medycyny P4, czyli medycyny personalizowanej, predyktywnej, prewencyjnej i partycypacyjnej, której celem jest umożliwienie kompleksowego podejścia do tematu zdrowia poprzez analizę rozległych zbiorów danych. W praktyce oznacza to odejście od reaktywnego modelu opieki zdrowotnej na rzecz modelu proaktywnego, skoncentrowanego na profilaktyce oraz wczesnym wykrywaniu potencjalnych chorób. Stan zdrowia pacjenta w medycynie 4P jest opisywany poprzez spersonalizowaną chmurę szczegółowych danych, takich jak pomiary biochemiczne, ocenę narażenia na czynniki ryzyka (np. stres, zanieczyszczenia) oraz dane genetyczne. Inteligentne technologie medyczne wspomagają autonomię oraz wygodę pacjenta jednocześnie zmniejszając biurokrację i koszty usług medycznych poprzez ograniczenie dokumentacji automatyzację procesów (Alonso, De La Torre Díez i Zapiraín, 2019; Briganti i Le Moine, 2020; Głos, 2017).

W ciągu ostatniej dekady algorytmy oparte na sztucznej inteligencji w postaci przenośnych urządzeń znalazły szerokie zastosowanie w kardiologii poprzez obserwowanie i analizę parametrów fizjologicznych oraz rejestrację sygnału elektrokardiograficznego. Zdalne monitorowanie zapisu EKG z wykorzystaniem takich urządzeń jak Fitbit czy Apple Watch 4 jak i aplikacji mobilnych, np. Kardia, umożliwia wczesne wykrywanie migotania przedsionków oraz wspiera zarówno pacjentów oraz lekarzy w dokładniejszej ocenie stanu zdrowia (Amisha i in., 2019; Briganti i Le Moine, 2020; Halcox i in., 2017). Systemy przenośnych urządzeń monitorujących zsynchronizowanych z smartfonem i opartych na analizie AI sprawdziły się również w przypadku endokrynologii, dostarczając stały przepływ informacji na temat poziomu glukozy we krwi pacjentów z cukrzycą, oraz w neurologii w celu wczesnego wykrywania ataków epilepsji (Briganti i Le Moine, 2020).

Modele sztucznej inteligencji znajdują szerokie zastosowanie w diagnostyce, obejmującej między innymi takie techniki jak radiografia rentgenowska, rezonans magnetyczny, endoskopia, ultrasonografia oraz patologia cyfrowa. Podejście to określane jest mianem diagnostyki komputerowo wspomaganej - CADx, czyli *computer-aided diagnosis*. W pulmonologii sztuczna inteligencja jest wykorzystywana do interpretacji wyników badań czynnościowych płuc. Oprogramowanie implementujące AI, zwłaszcza z ekspertyzą pulmonologów, charakteryzuje się wyższą dokładnością diagnostyczną niż samodzielna analiza specjalistów (Das i in., 2023; Topalovic i in., 2019). Konwolucyjne sieci neuronowe (CNN), czyli modele głębokiego uczenia specjalizujące się w analizie obra-

zów, sprawdziły się w przypadku wykrywania zapalenia i raka płuc, wirusa COVID-19 oraz innych anomalii na zdjęciach rentgenowskich klatki piersiowej (Hussain i in., 2021; Ismael i Şengür, 2021; Lee, Lee i Kwon, 2023; Rajaraman, Candemir i in., 2018). W dziedzinie gastroenterologii wykorzystano CNN do przetwarzania obrazów z endoskopii i ultrasonografii w celu skutecznego wykrywania nieprawidłowości takich jak refluks żołądkowo-przełykowy i zanikowe zapalenie błony śluzowej żołądka (Briganti i Le Moine, 2020; Yang i Bang, 2019). CADx okazało się również skuteczną metodą w przypadku klasyfikacji komórek zarażonych malarią oraz rozpoznawania choroby zwyrodnieniowej stawu kolanowego (Al-rimy i in., 2023; Rajaraman, Antani i in., 2018). Liczne badania poświęcone zastosowaniu metod sztucznej inteligencji w diagnostyce medycznej obrazowej wskazują na wysoką skuteczność modeli głębokiego uczenia w zadaniach klasyfikacji binarnej oraz wieloklasowej, wykrywania obiektów na zdjęciach oraz ich segmentacji (Elyan i in., 2022). Wynika to z faktu, że systemy wizji komputerowej oparte na sieciach neuronowych uczą się bezpośrednio z obrazów, czego konsekwencją jest identyfikacja skomplikowanych wzorców i zależności często niezauważanych przez doświadczonych lekarzy. Modele te funkcjonują jako systemy typu ”black-box”, co pozwala im zakwalifikować subtelne przypadki chorób i wykryć je w wczesnym stadium (Richens i Buchard, 2021).

Szczególnie istotnym zastosowaniem wizji komputerowej w systemach *computer-aided diagnosis* stanowi dermatologia, której problematyki podjęto się w niniejszej pracy. W kolejnych podrozdziałach przeprowadzono analizę porównawczą dotychczasowych metod diagnostycznych w dermatologii z nowoczesnymi metodami diagnostyki komputerowo wspomaganej opierającymi się na algorytmach uczenia maszynowego.

2.2 Przegląd wstępnych metod diagnostycznych

Tradycyjnie wstępna diagnostyka w dermatologii obejmuje badanie dermoskopowe lub wideodermoskopowe, polegające na ocenie znamienia w około dziesięciokrotnym powiększeniu. W 1994 roku Stolz wraz z współpracownikami zaproponował algorytm dermoskopowy ABCD, opierający się na wielowymiarowej analizie następujących cech: asymetrii (A), nierównych i postrzępionych brzegów (B), zróżnicowania kolorów (C) oraz obecności zmian morfologicznych (D), takich jak kropki, smugi, kuleczki lub sieci pigmen-

towe. Według innych interpretacji kryterium ”D”dotyczy średnicy zmiany przekraczającej 6 mm. Na podstawie sumy iloczynów stopnia spełnienia poszczególnych kryteriów ABCD oraz ich wag obliczany jest wskaźnik badania dermoskopowego TDS (Total Dermatoscopy Score), stanowiący półilościową miarę znacząco poprawiającą skuteczność diagnostyczną, szczególnie w przypadku osób niebędących dermatologami, takich jak pacjenci. Znamiona o wartości TDS poniżej 4,75 uznawane są za łagodne, w przedziale 4,76-5,45 za podejrzane i wymagającej rutynowej kontroli dermoskopowej, a powyżej 5,45 za wysoce podejrzane w kierunku czerniaka (Nachbar i in., 1994; Rutkowski i in., 2016).

Tabela 2.1. Algorytm ABCD

Kryterium	Liczba punktów do przyznania	Waga
A - asymetria	0 - brak asymetrii w osi X i Y 1 - asymetria w jednej z osi 2 - asymetria w obu osiach	1,3
B - nieregularność granicy zmiany	0 - brak nagłych zakończeń zmiany 1 - nagłe zakończenie w jednym segmencie ... 8 - nagłe zakończenie w ośmiu segmentach	0,1
C - zróżnicowanie kolorów zmiany	1 - jeden kolor 2 - dwa kolory ... 6 - sześć kolorów	0,5
D - elementy strukturalne	1 - jeden element ... 5 - pięć elementów	0,5

Źródło: Opracowanie własne na podstawie (Nachbar i in., 1994)

W 2004 roku rozszerzono tę zasadę o dodatkową cechę ”E”, oznaczającą ewolucję rozmiaru, kształtu, koloru, powierzchni oraz innych objawów, co pozwala uwzględnić dynamiczny charakter nowotworu (Abbasi i in., 2004; Duarte i in., 2021). W literaturze przedstawiono również podobny algorytm CASH - kolor (C), architektura (A), symetria (S), homogeniczność (H) - który rozszerza ABCD o analizę wzorców oraz nie wymaga wag, przez co jest prostszy w użyciu (Henning i in., 2008). W diagnostyce potencjalnie złośliwych zmian skórnych wykorzystywana jest również zasada ”brzydkiego kaczątka”polegająca na identyfikacji znamion odbiegających wyglądem od innych typowo łagodnych zmian występujących u pacjenta. Znamiona znacząco różniące się od pozosta-

łych uznaje się za potencjalnie złośliwe, ponieważ znamiona barwnikowe należy oceniać nie tylko na podstawie cech morfologicznych pojedynczej zmiany, ale należy je rozpatrywać w kontekście pozostałych znamion pacjenta (Grob i Bonerandi, 1998; Kaminska-Winciorek i Spiewak, 2011). Kolejną metodą wstępnej oceny złośliwości zmiany skórnej jest skala siedmiopunktowa (7PCL) opracowana w latach 80. Znamię klasyfikuje się jako podejrzane, jeżeli obecne są co najmniej trzy z danych cech: zmiana wielkości zmiany, nieregularna pigmentacja, nieregularne brzegi, stan zapalny, swędzenie, średnica większa niż 7 mm, sączenie i strupy. W 1989 udoskonalono metodę siedmiu punktów o wagi, które opracowano na podstawie częstotliwości występowania danych objawów w przypadku czerniaka złośliwego skóry. Dwa punkty przyznawane są dla zmiany wielkości, nieregularnej pigmentacji oraz nieregularnych brzegów, natomiast pozostałe cechy oceniane są na jeden punkt. Wynik większy lub równy trzy stanowi wskazanie do badania histopatologicznego (Congdon i Davis, 2023; MacKie, 1990; Mackie, 1989; Walter i in., 2013). Opracowano również algorytmy o podejściu krokowym, takie jak metodę Menziesa, metoda ”chaosu i wzorów”oraz algorytm TADA. Metoda Menziesa jest szczególnie czuła w wykrywaniu czerniaka i składa się z dwóch etapów. Badanie wstępne polega na ocenie symetrii zmiany oraz jednorodności koloru - jeśli oba kryteria są spełnione, znamię jest uznawane za łagodne. W przeciwnym razie analizuje się cechy typowe dla czerniaka, takie jak niebiesko-białawy welon, liczne brązowe lub niebiesko-szare kropki, pseudopodia i smugi promieniste, odbarwienia bliznopodobne, obwodowo ułożone czarne kropki lub grudki, pięć lub sześć kolorów oraz poszerzona siatka. Spełnienie któregokolwiek z tych kryteriów sugeruje wysokie prawdopodobieństwo czerniaka (Menzies i in., 1996). Metoda ”chaosu i wzorów”opiera się na drzewie decyzyjnym badającym obecność ”chaosu”w zmianie, czyli asymetrie struktury i koloru, a następnie analizowane są wzory charakterystyczne dla czerniaka i pozostałych złośliwych nowotworów (Rosendahl i in., 2012). Skala TADA definiuje algorytm triażowy, którego pierwszy etap polega na badaniu znamienia pod kątem trzech powszechnie występujących nowotworów łagodnych (włókniaka twardego, naczyniaka i rogowacenia łojotokowego). Jeżeli zmiana zostanie zakwalifikowana jako jeden z tych trzech nowotworów, powinna być rutynowo monitorowa, lecz jest wykluczona z dalszej oceny pod kątem złośliwości. W kolejnym kroku oceniana jest obecność nieuporządkowanego lub asymetrycznego rozmieszczenia kolorów i struktur - ich wystąpienie stanowi wskazanie do biopsji. Jeśli

takie cechy nie są obecne, sprawdzane jest sześć dodatkowych cech powszechnie występujących u czerniaka oraz innych zmian nowotworowych (Rogers i in., 2017).

Badanie dermoskopowe stosowane w połączeniu z algorytmami diagnostycznymi oraz wywiadem z pacjentem, stanowi skuteczną metodę profilaktyki czerniaka ze względu na swoją szybkość, nieinwazyjność oraz możliwość ograniczenia konieczności wykonania biopsji skóry. Dokładność rozpoznań klinicznych dla zmian barwnikowych po zastosowaniu dermoskopii wzrasta o około 30% w porównaniu z badaniem okiem nieuzbrojonym. Należy jednak podkreślić, że algorytmy dermoskopowe wykazują ograniczoną skuteczność w przypadku wykrywania wczesnych czerniaków o średnicy poniżej 5 mm, czerniaków guzkowych i bezbarwnikowych oraz zmian w odrębie owłosionej skóry głowy, dłoni i stóp, twarzy, błon śluzowych jamy ustnej i narządów płciowych (Davis i in., 2020; Kaminska-Winciorek i Spiewak, 2011; Rutkowski i in., 2016; Sonthalia, Yumeen i Kaliyadan, 2025). Dermoskopię cechuje również wysoka zależność od doświadczenia specjalisty, ponieważ wymaga ona zarówno szkoleń jak i użycia metod klinicznych, rozumowania poznawczego, diagnostyki różnicowej i znajomości historii zdrowia pacjenta. Badanie dermoskopowe nie stanowi ostatecznej diagnozy i powinno być połączone z histopatologią, ponieważ umożliwia one jednoznaczne rozstrzygnięcie diagnostyki w przypadkach, w których jest widoczny wyraźny wzorzec dermoskopowy (Sonthalia, Yumeen i Kaliyadan, 2025; Yélamos i in., 2019).

2.3 Głębokie uczenie w dermatologii

2.3.1 Podstawy deep learning

W 2000 roku opracowano pierwszy komputerowy system dermoskopii cyfrowej, klasyfikujący zmiany skórne na podstawie cech charakterystycznych czerniaka opisanych w metodzie ABCD i siedmiu punktów (Gutkowicz-Krusin i in., 2000). Wraz z dynamicznym rozwojem sztucznej inteligencji rozpoczęto badania nad jej zastosowaniem w medycynie, w tym w dermatologii (Goodfellow, Bengio i Courville, 2016). Sztuczna inteligencja (AI, ang. *artificial intelligence*) stanowi szeroką dziedzinę badań dotyczącą zdolności systemów komputerowych do symulowania procesów poznawczych. Uczenie maszynowe (ML, ang. *machine learning*) jest podzbiorem sztucznej inteligencji poświęconym algorytmom potrafiącym uczyć się z danych oraz identyfikować wzorce bez konieczności do-

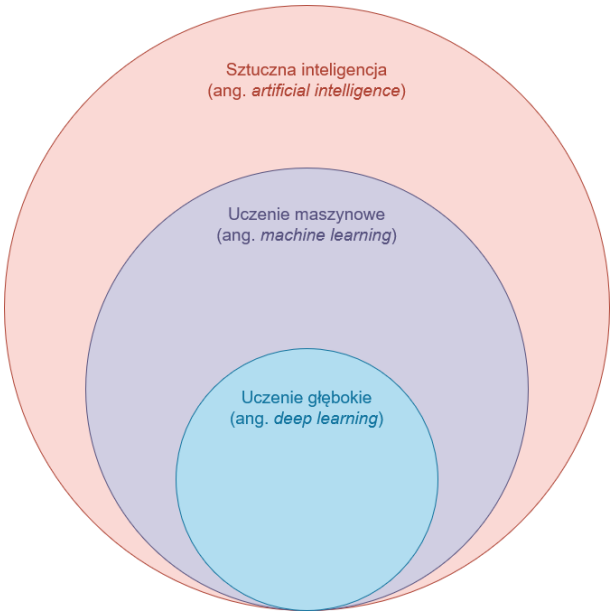

Rysunek 2.1. Relacje między sztuczną inteligencją, uczeniem maszynowym i głębokim uczeniem

Źródło: opracowanie własne

starczania instrukcji. Głębokie uczenie (DL, ang. *deep learning*) to obszar uczenia maszynowego polegający na uczeniu głębokich sieci neuronowych, czyli sieci neuronowych składających się z wielu warstw. *Deep learning* radzi sobie szczególnie dobrze z wykrywaniem złożonych struktur i zależności, osiągając przełomowe wyniki zarówno w zadaniach rozpoznawania obrazów i dźwięków jak i rozumienia języka naturalnego i tłumaczeniu (Goodfellow, Bengio i Courville, 2016; LeCun, Bengio i Hinton, 2015; Russell i Norvig, 2022).

Sieci neuronowe (ANN, ang. *artificial neural network*) definiowane są jako systemy przetwarzania informacji inspirowane funkcjonowaniem układu nerwowego. W dziedzinie widzenia komputerowego (CV, *computer vision*) standardem stały się konwolucyjne sieci neuronowe (CNN, ang. *convolutional neural network*), których architektura jest inspirowana korą wzrokową(Ghosh i in., 2020; Hubel i Wiesel, 1968). Podstawy teoretyczne CNN zostały opracowane już w latach 60, lecz ich rozwój rozpoczął się dopiero w 2012 roku wraz z prezentacją architektury AlexNet (Hinton i in., 2012; Hubel i Wiesel, 1968). Tradycyjna konwolucyjna sieć neuronowa składa się z jednej lub wielu warstw konwolucyjnych oraz warstw łączenia (ang. *pooling*), po których następuje jedna lub wiele warstw w pełni połączonych (FC, ang. *fully connected*). Warstwa konwolucyjna składa się z kliku jąder konwolucyjnych które obliczają mapy cech danych wejściowych,

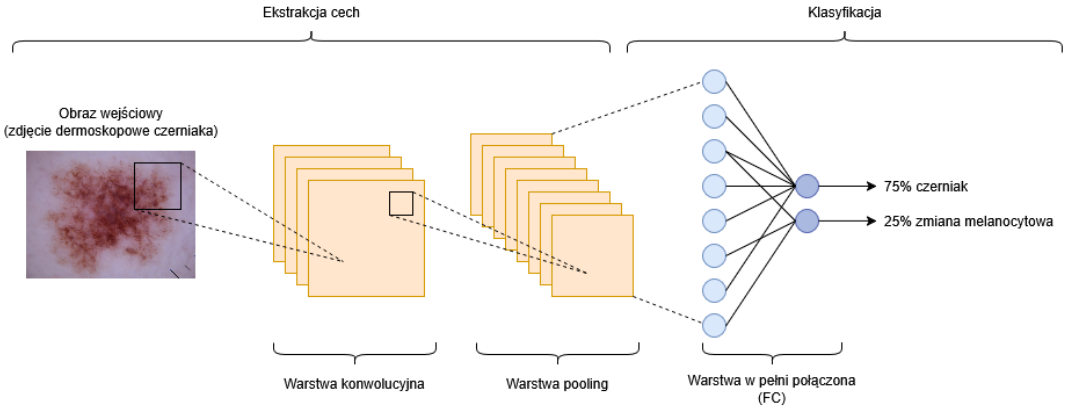

Rysunek 2.2. Podstawowa architektura konwolucyjnej sieci neuronowej

Źródło: opracowanie własne na podstawie (Ghosh i in., 2020)

jednocześnie ucząc się ich reprezentacji. Kolejne warstwy przetwarzają mapy cech z warstw poprzednich, stosując nieliniowe funkcje aktywacji i generując coraz bardziej abstrakcyjne uogólnienia obrazu. Warstwa pooling redukuje liczbę parametrów poprzez zagregowaniu danych z poprzednich warstw, natomiast końcowa warstwa FC pełni funkcję klasyfikatora (Ghosh i in., 2020). W efekcie warstwy konwolucyjne najniższych poziomów wykrywają podstawowe cechy, natomiast wyższe warstwy identyfikują bardziej złożone zależności. W przypadku dermoskopowego zdjęcia czerniaka najniższe warstwy przetwarzają podstawowe cechy, takie jak kolor, a kolejne analizują zależności pomiędzy pojedynczymi pikselami, wykrywając cechy morfologiczne. Następnie warstwa *fully connected* przypisuje prawdopodobieństwo przynależności obrazu do jednej z klas (Ghosh i in., 2020).

W związku z opisanym mechanizmem wiele badaczy analizujących możliwości konwolucyjnych sieci neuronowych w dziedzinach medycznych decyduje się na zastosowanie uczenia transferowego (ang. *transfer learning*). Uczenie transferowe polega na wykorzystaniu wag wstępnie wyszkolonego modelu na dużym, ogólnym zbiorze danych w innym, bardziej wyspecjalizowanym zadaniu, często z mniejszym zbiorem danych. Najczęściej stosowane modele wstępnie wytrenowane to AlexNet, VGGNet, GoogLeNet, DenseNet, EfficientNet oraz ich liczne modele pochodne i mieszane. Technika *transfer learning* jest szeroko wykorzystywana w analizie obrazów medycznych w celu ich segmentacji i klasyfikacji (Ghosh i in., 2020; Mahbod i in., 2020).

Wydajność modeli uczenia maszynowego jest mierzona za pomocą kilku podstawowym metryk. Dokładność (ang. *accuracy*) jest najprostszą miarą określającą zdolność

modelu do dokonywania poprawnych przewidywań. Jest stosunkiem liczby poprawnych predykcji do całkowitej liczby przykładów w zbiorze testowym (Erickson i Kitamura, 2021; Grandini, Bagli i Visani, 2020; Rainio, Teuho i Klén, 2024). Dokładność można wyrazić następujących wzorem:

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FP} + \text{TN} + \text{FN}} \tag{2.1}$$

gdzie:

- TP - liczba prawdziwie pozytywnych klasyfikacji,
- TN - liczba prawdziwie negatywnych klasyfikacji,
- FP - liczba fałszywie pozytywnych klasyfikacji,
- FN - liczba fałszywie negatywnych klasyfikacji.

Dokładność nie jest optymalną metryką szczególnie w przypadku zbiorów danych, w których liczebności klas nie są równe. Jeżeli jedna klasa ma znacznie większą liczebność, model może osiągać wysoką dokładność, jednocześnie ignorując rzadkie, lecz kluczowe klinicznie przypadki, takie jak zmiany złośliwe (Grandini, Bagli i Visani, 2020).

W przypadku klasyfikacji wieloklasowej szczególnie przydatna jest macierz pomyłek (ang. *confusion matrix*). Przedstawia ona zestawienie liczby przypadków rzeczywistych i przewidzianych przez model dla każdej z klas, co pozwala ocenić, w jakim stopniu model rozróżnia każdą z klas i z jakimi klasami je myli. Elementy znajdujące się na głównej przekątnej macierzy odpowiadają poprawnym klasyfikacjom. Macierz pomyłek może być normalizowana względem liczby przykładów w klasie, co jest szczególnie przydatne przy niezbalansowanych zbiorach danych (Rainio, Teuho i Klén, 2024).

!!!

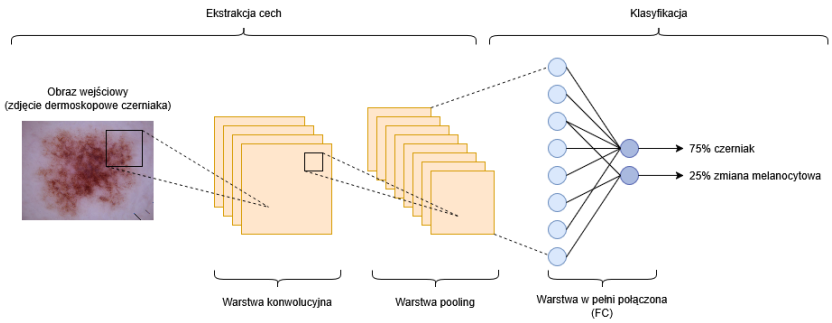

Rysunek 2.3. Przykładowa macierz pomyłek z pracy

Źródło: opracowanie własne na podstawie

Precyzja (ang. *precision*) określa odsetek prawidłowo sklasyfikowanych pozytywnych przypadków wśród wszystkich predykcji pozytywnych. Wysoka precyzja oznacza, że model ma niską tendencję do klasyfikowania negatywnych przypadków jako pozytywne. Metryka ta jest szczególnie istotna w sytuacjach, w których pomyłki wiążą się z wysokim kosztem (Erickson i Kitamura, 2021; Rainio, Teuho i Klén, 2024).

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \tag{2.3}$$

Zwiększenie precyzji może odbyć się wyłącznie kosztem zmniejszenia pełności, a wzrost pełności spowoduje spadek precyzji, wobec czego konieczne jest znalezienie kompromisu między nimi bądź priorytetyzacja jednej z metryk. W diagnostyce czerniaka złośliwego kluczowa jest pełność, ponieważ koszt konsultacji lub biopsji jest niewielki w porównaniu z ryzykiem przeoczenia zmiany złośliwej (Grandini, Bagli i Visani, 2020; Rainio, Teuho i Klén, 2024).

W badaniach medycznych często stosuje się również swoistość (ang. *specificity*), definiowaną jako odsetek prawidłowo rozpoznanych przypadków negatywnych. Swoistość odzwierciedla zdolność modelu do unikania ”fałszywych alarmów”(Rainio, Teuho i Klén, 2024).

$$\text{Specificity} = \frac{\text{TN}}{\text{TN} + \text{FP}} \tag{2.4}$$

Wynik F1 stanowi średnią harmoniczną z precyzji i pełności. Jest szczególnie przydatny w przypadku niezbalansowanych zbiorów, ponieważ odzwierciedla kompromis między obiema miarami (Erickson i Kitamura, 2021; Rainio, Teuho i Klén, 2024).

$$\text{F1 Score} = \frac{2\text{TP}}{2\text{TP} + \text{FN} + \text{FP}} \tag{2.5}$$

Krzywa charakterystyki operacyjnej odbiornika (ang. *Receiver Operating Characteristic Curve*) przedstawia zależność między odsetkiem prawdziwie pozytywnych i fałszywie pozytywnych klasyfikacji. AUC (ang. *Area Under the Curve*) określa obszar pod krzywą ROC i stanowi miarę jakości klasyfikatora. Wartość AUC równa 0,5 oznacza model działający na poziomie losowego klasyfikatora, 1 świadczy o perfekcyjnym modelu (Erickson i Kitamura, 2021).

2.3.2 Klasyfikacja binarna

Bassel i in. (2022) opracowali metodę agregującą wyniki wielu modeli w celu klasyfikacji nowotworów skóry jako złośliwe lub łagodne. Zbiór danych obejmował 1000 obrazów czerniaka i 1000 zdjęć nowotworów łagodnych pochodzących z archiwów ISIC. W badaniu wykorzystano maszynę wektorów nośnych, lasy losowe oraz metodę k-najbliższych sąsiadów, a także głębokie sieci neuronowe takie jak Xception, ResNet50 oraz VGG16. Metoda osiągnęła dokładność 90,9%, wynik F1 równy 89,6%, czułość 88,6% oraz AUC 91,7%.

W 2019 Adegun i Viriri (2020) przedstawili system oparty na głębokich sieciach neuronowych rozróżniający czerniaka od pozostałych zmian skórnych. Model trenowano na zbiorach zdjęć dermoskopowych ISIC 2017 oraz PH2, łącznie obejmujących 2200 obrazów w zbiorze treningowym i 660 w testowym. Autorzy zaproponowali własną architekturę konwolucyjnej sieci neuronowej typu koder-dekoder oraz zastosowali techniki augmentacji obrazu, takie jak losowe obroty. Metoda osiągnęła dokładność 95%, czułość 97% i swoistość 96%.

Alzubaidi i in. (2021) zaproponowali rozwiązanie oparte na głębokich konwolucyjnych sieciach neuronowych, wykorzystuujące zbiory ISIC z konkursów z lat 2016-2020, 170 obrazów z zbioru MED-NODE oraz 1300 zdjęć z zbioru Dermfit. Zastosowali augmentację danych zwiększającą liczbę przykładów do 200 000 oraz techniki transfer learning oraz double transfer learning. W badaniu uzyskano dokładność wynoszącą 98,57%, pełność 97,9%, precyzja 99,18% oraz F1 równe 98,53%.

Jojoa Acosta i in. (2021) przedstawili architekturę składającą się z dwóch konwolucyjnych sieciach neuronowych. Pierwsza generowała maskę obszaru istotnego (ang. *region of interest*), natomiast druga była oparta na architekturze ResNet152 i klasyfikowała zmiany jako łagodne i złośliwe. Wykorzystano dane z konkursu ISIC z 2017 roku oraz dodatkowo dane ze zbioru PH2, zastosowano technikę *downsampling* dla klasy łagodnej, czyli zmniejszono liczbę przykładów z tej klasy, oraz technikę augmentacji danych. Najlepszy model osiągnął czułość 82%, swoistość 92,5%, dokładność 90,4%.

Menegola i in. (2017) przeanalizowali działanie głębokich sieci neuronowych w połączeniu z różnymi metodami *transfer learning*. Autorzy wykorzystali zbiór Interactive Atlas of Dermoscopy oraz dane z konkursu ISIC 2017. Przetestowano modele ImageNet, VGG-M i VGG-16, wykazując, że *fine-tuning* znacząco poprawia wyniki klasyfikację, a *transfer learning* jest najbardziej efektywny w przypadku modeli uczonych na danych o wysokim stopniu ogólności, takich jak ImageNet.

2.3.3 Klasyfikacja wieloklasowa

Alwakid i in. (2022) przedstawili trzy etapową technikę polegają na wstępnym poprawieniu jakości obrazu, segmentacji obszaru istotnego a następnie analizy przez zmodyfikowany model ResNet-50. Autorzy wykorzystali zbiór HAM10000 opublikowany przez International Skin Imaging Collaboration, który obejmuje siedem klas: raka podstawnokomórkowego, czerniaka złośliwego, włókniaka twardego, łagodne rogowacenie, zmiany naczyniowe oraz melanocytowe. Opracowana metoda osiągnęła dokładność 86%, precyzję 84%, pełność 86% oraz F1 na poziomie 86%, znacznie przewyższając wyniki wcześniejszych badań.

Mahbod i in. (2020) zbadali wpływu kadrowania obrazów zmian skórnych oraz zastosowania uczenia transferowego na modelach EfficientNetB0, EfficientNetB1 i SeResNeXt-50. Autorzy zaproponowali podejście polegające na łączeniu wyników kliku modeli w jeden system decyzyjny, osiągając rezultaty porównywalne z ówcześnie najlepszymi wynikami modeli w rankingu ISIC dla konkursu z 2018 roku, z którego uzyskano dane.

W 2022 roku Lu i Firoozeh Abolhasani Zadeh (2022) przedstawili usprawniony model oparty na głębokiej sieci neuronowej XceptionNet. Dodatkowo zastosowali funkcje aktywację Swish oraz augmentację obrazów. Model wytrenowano na podstawie da-

nych z zbioru HAM10000. Metoda osiągnęła dokładność 100%, czułość 94,05%, precyzję 97,07% oraz wynik F1 95.53%.

Hosseinzadeh Kassani i Hosseinzadeh Kassani (2019) porównali popularne głębokie konwolucyjne sieci neuronowe Xception, AlexNet, VGGNet oraz ResNet w zadaniu klasyfikacji wieloklasowej zmian skórnych. Wykorzystano zbiór ISIC 2018, który obejmuje 10 015 zdjęć dermoskopowych i siedem kategorii zmian skórnych. Najlepsze wyniki osiągnął model ResNet50 z dokładnością wynoszącą 92,08%, F1 92,74%, precyzją 93,73% i pełnością 92,53%.

Han i in. (2018) dokonali *fine-tuning* na konwolucyjnej sieci neuronowej ResNet-152 w celu klasyfikacji 12 kategorii zmian skórnych - raka podstawnokomórkowego, płaskonabłonkowego i śródnabłonkowego, czerniaka złośliwego, rogowacenia słonecznego i łojotokowego, plam soczewicowatych, włókniaka twardego, ziarniniaka ropnego, naczyniaka, brodawki i znamienia melanocytowego, potocznie nazywanego pieprzykiem. *Fine-tuning* obejmował 19 398 obrazów z zbiorów Asan, MED-NODE, Dermofit, Hallym oraz obrazów pobranych z różnych internetowych atlasów dermatologicznych. Model osiągnął wyniki porównywalne do 16 dermatologów.

Kawahara, Bentaieb i Hamarneh (2016) w 2016 roku zaprezentowali klasyfikator liniowy wytrenowany na podstawie cech wyodrębnionych z głębokiej sieci konwolucyjnej. Model został wyuczony na zbiorze danych Dermofit i rozróżniał dziesięć kategorii zmian skórnych z większą dokładnością niż ówczesne wyniki innych metod dla tego samego zbioru danych.

Esteva i in. (2017) wytrenowali konwolucyjną sieć neuronową GoogleNetInceptionV3 na 129 450 przykładach obejmujących 2032 jednostek chorobowych i porównali jej wydajność z 21 dermatologami. Szczególnie skupiono się na rozróżnianiu nowotworów keratynocytowych (rak podstawnokomórkowy i płaskonabłonkowy) od łagodnych rogowaceń oraz rozróżnianiu czerniaków złośliwych i znamion melanocytowych. Sieć wykazała się skutecznością na poziomie porównywalnym z dermatologami. Autorzy zasugerowali wykorzystanie tego typu rozwiązań do zapewnienia powwszechnego dostępu do opieki diagnostycznej po niższych kosztach przy pomocy urządzeń mobilnych.

2.3.4 Rozwiązania mobilne

W 2019 of Computer Science i in. (2020) przedstawili aplikację mobilną na systemy Android klasyfikującą zmiany skórne na łagodne i złośliwe. Autorzy zastosowali własny, trzy warstwowy model konwolucyjnej sieci neuronowej, VGG-16 oraz Google Inception V3. Model Inception V3 osiągnął dokładność 81% i czułość 84%. Dane uzyskano z archiwów ISIC a do trenowania wykorzystano 1758 obrazów poddanych technice augmentacji danych. Wytrenowany model Google Inception V3 przekonwertowano na model Tensorflow a następnie zaimportowano do prostej aplikacji androidowej bez interfejsu użytkownika.

W aplikacji przedstawionej przez Wibowo, Adhi Hartanto i Wisnu Wirawan (2020) wykorzystano model MobileNet v2, cechujący się niewielkim rozmiarem oraz niskim opóźnieniu, zaprojektowany w celu użycia na systemach mobilnych. Zebrano 640 obrazów z oficjalnej strony International Skin Imaging Collaboration i podzielono na zbiór treningowy, testowy oraz walidacyjny. Skupiono się na dwóch rodzajach zmian skórnych - czerniaku złośliwym oraz rogowaceniu słonecznym, które może się przekształcić w raka płaskonabłonkowego. Wykorzystano technikę *region of interest*. Model przetestowano na fizycznie wydrukowanych zdjęciach zmian skórnych, na zdjęciach na kompyterze z dziesięcio centrymetrowym oddaleniem od kamery oraz na faktycznych zdjęciach skóry z czterokrotnym powiększeniem. Model uzyskał 70% dokładność w zadaniu klasyfikacyjnym ze zdjęć kamerą telefonu i 90% dokładności z zdjęciami ze zbioru.

Kousis i in. (2022) zbadali możliwości jedenastu konwolucyjnych sieci neuronowych w zadaniu klasyfikacji siedmiu zmian skórnych. Dane uzyskano z zbioru HAM10000, który obejmuje 10 000 obrazów zmian skórnych. Najlepsze wyniki osiągnął model DenseNet169 z dokładnością 92,25% i pełnością 93,59%. Autorzy wykorzystali uczenie transferowe oraz augmentację zdjęć. Model przekonwertowano do formatu tensorlite tworzono aplikację mobilną android, która zbiera również informacje o ekspozycji na UV oraz lokalizacji użytkownika.

Dai i in. (2019) przedstawili aplikację mobilną przeznaczoną dla systemu iOS, wykorzystującą autorską sieć konwolucyjną wytrenowaną na podstawie 10 015 obrazów z zbioru HAM10000. Model został następnie przekonwertowany na format mobilny za pomocą biblioteki Core ML, co umożliwiło dokonanie predykcji w czasie niemal rzeczywistym. Po zrobieniu zdjęcia przez użytkownika aplikacja prezentuje na ekranie telefonu

najbardziej prawdopodobną klasę zmiany skórnej. Autorzy nie opublikowali szczegółowych wyników walidacji ani metryk oceniających skuteczność modelu.

Kong i in. (2021) przeprowadzili analizę aplikacji wykrywających raka skóry dostępnych dla konsumentów poprzez platformy dystrybucji aplikacji mobilnych takie jak Google Play (aplikacje na systemy Android) oraz App Store (aplikacje na systemy iOS).

!!OPISAĆ RESZTĘ BADAŃ PO DOSTANIU DOSTĘPU!!!!!!!!!!!!!!!!!!!

cyjnego. W praktyce klinicznej zdjęcia zmian skórnych mogą być wykonywane różnymi urządzeniami w różnych warunkach, co może obniżyć skuteczność algorytmu (Kelly i in., 2019). Dodatkowo modele mogą uczyć się cech nieistotnych klinicznie, takich jak włosy lub odbicia światła. W jednym badaniu wykazano, że sztuczna inteligencja traktowała obecność linijki na zdjęciach dermoskopowych jako cechę wskazującą na nowotwór, ponieważ lekarze częściej mierzyli zmiany podejrzane o złośliwość (Esteva i in., 2017). Wiele modeli klasyfikacji zmian skórnych nie uwzględnia istotnych czynników klinicznych, takich jak wiek pacjenta, ekspozycja na promieniowanie UV czy historia nowotworów skóry w rodzinie. Ponadto, obecnie sztuczna inteligencja nie jest w stanie zastosować metody "brzydkiego kaczątka", ponieważ algorytmy nie potrafią jeszcze porównywać wielu znamion u jednego pacjenta, aby określić, które z nich odbiega od jego fenotypu znamionowego.

2.4.3 Brak wyjaśnialności modeli

Modele głębokiego uczenia działają na zasadzie "czarnej skrzynki", co utrudnia w wielu przypadkach uzasadnienie decyzji podjętych przez model. W medycynie kluczowe jest zrozumienie oraz weryfikacja diagnozy, dlatego tworzenie wyjaśnialnej sztucznej inteligencji (XAI, ang.*Explainable Artificial Intelligence*) stanowi poważne wyzwanie w wdrażaniu głębokiego uczenia (Ali i in., 2023; He i in., 2019; Kelly i in., 2019).

2.4.3.1 Prywatność i bezpieczeństwo danych

Skuteczne modele głębokiego uczenia wymagają dużych, wolnych od uprzedzeń i dobrze opisanych zbiorów danych. Ich pozyskiwanie wiąże się jednak z koniecznością ich anonimizacji oraz uzyskania zgody od pacjentów. Dane powinny być przechowywane i wykorzystywane z zachowaniem wysokiego stopnia cyberbezpieczeństwa oraz zgodnie z regulacjami prawnymi dotyczącymi ochrony danych (Farhud i Zokaei, 2021; He i in., 2019). Integracja danych medycznych jest dodatkowo utrudniona przez brak standaryzacji. He i in. (2019) wskazują na potrzebę stworzenia globalnych standardów archiwizacji danych medycznych, analogicznych do standardów obrazowania DICOM (ang. *Digital Imaging and Communications in Medicine*).

2.4.4 Regulacje prawne i odpowiedzialność

Kluczowym krokiem we wprowadzaniu bezpiecznych i efektywnych algorytmów uczenia maszynowego do praktyki medycznej są odpowiednie regulacje i rygorystyczna kontrola jakości (He i in., 2019; Kelly i in., 2019). W Unii Europejskiej szczególne znaczenie ma Ogólne Rozporządzenie o Ochronie Danych oraz rozporządzenie o sztucznej inteligencji "AI Act"(„Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2016/679 z dnia 27 kwietnia 2016 r. w sprawie ochrony osób fizycznych w związku z przetwarzaniem danych osobowych i w sprawie swobodnego przepływu takich danych (RODO)", 2016; „Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2024/1689 z dnia 13 czerwca 2024 r. ustanawiające zharmonizowane przepisy dotyczące sztucznej inteligencji (Akt o sztucznej inteligencji)", 2024). Zgodnie z art. 22 RODO każda osoba ma prawo nie podlegać decyzjom podejmowanym wyłącznie automatycznie oraz ma prawo wymagać wyjaśnienia decyzji podjętych przez algorytm, co na obecnym etapie rozwoju technologii AI jest często niemożliwe (He i in., 2019; „Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2016/679 z dnia 27 kwietnia 2016 r. w sprawie ochrony osób fizycznych w związku z przetwarzaniem danych osobowych i w sprawie swobodnego przepływu takich danych (RODO)", 2016). Rozporządzenie AI Act ma na celu zdefiniowanie sztucznej inteligencji oraz ustanowienie ram prawnych dotyczących tworzenia usług i produktów opartych na AI. Systemy medyczne wykorzystujące sztuczną inteligencję w większości należą do kategorii wysokiego ryzyka, co wiąże się z koniecznością spełnienia wymogów dotyczących zarządzania ryzykiem, jakości danych, nadzoru ludzkiego oraz cyberbezpieczeństwa („Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2024/1689 z dnia 13 czerwca 2024 r. ustanawiające zharmonizowane przepisy dotyczące sztucznej inteligencji (Akt o sztucznej inteligencji)", 2024; Van Kolfschooten i Van Oirschot, 2024).

2.4.5 Problemy społeczne

Wdrożenie AI w medycynie wymaga odpowiedniego wyszkolenia kadry medycznej. Lekarze powinni znać zarówno możliwości jak i ograniczenia technologii głębokiego uczenia, aby móc z niej bezpiecznie korzystać. Badania wykazują, że pacjenci i lekarze obawiają się, że adaptacja sztucznej inteligencji w opiece medycznej będzie skutkować de-

personalizacją medycyny i ograniczeniem roli lekarza w procesie diagnostycznym (Tang, Li i Fantus, 2023).

2.4.6 Wyzwania związane z aplikacjami mobilnymi

W przypadku aplikacji mobilnych dodatkowym problemem jest jakość zdjęć wykonywanych przez użytkowników. Rozmazanie, niewłaściwe oświetlenie lub zbyt małe powiększenie mogą znacząco obniżyć skuteczność modelu i prowadzić do błędnych wyników.

2.5 Podsumowanie

Rozwój sztucznej inteligencji oraz powszechne stosowanie smartfonów stwarzają szansę na transformację diagnostyki i leczenia chorób. Systemy oparte na sieciach neuronowych osiągnęły dojrzałość technologiczną i stały się bardziej niezawodne, często osiągając wyniki porównywalne i lepsze od specjalistów, dzięki czemu część z nich znalazła już zastosowanie w praktyce klinicznej (Li i in., 2022). Na obecnym etapie rozwoju głębokie uczenie posiada ogromny potencjał w diagnostyce obrazowej i potrafi wykrywać subtelne sygnały niewidoczne dla człowieka. Należy jednak podkreślić, że sztuczna inteligencja powinna pełnić funkcję wsparcia dla lekarzy poprzez ich odciążenie, redukcję błędów oraz standaryzację decyzji, a nie ich zastępować. Chociaż wiele badań porównuje skuteczność algorytmów uczenia maszynowego ze skutecznością lekarzy, najlepsze rezultaty osiąga się w modelu współpracy, w którym lekarze korzystają z inteligentnych narzędzi jako elementu wspomagającego proces diagnostyczny (Kelly i in., 2019). Z tego względu wprowadzanie AI do praktyki klinicznej powinno odbywać się wyłącznie pod nadzorem specjalistów, tak aby technologia stanowiła realne wsparcie zarówno dla lekarzy, jak i pacjentów (Kelly i in., 2019; Naeem i in., 2020).

Aby możliwe było przełożenie wyników badań na skuteczne wdrożenia kliniczne, konieczne są dalsze prace nad następującymi aspektami modeli głębokiego uczenia:

- interpretowalność modeli - zwiększenie możliwości wyjaśniania decyzji podejmowanych przez sztuczną inteligencję oraz eliminacja czynników zakłócających proces uczenia,
- rozwój regulacji prawnych - dostosowanie przepisów do specyfiki systemów AI stosowanych w medycynie,

- definicja ram etycznych -określenie odpowiedzialności za decyzje oraz roli lekarza i sztucznej inteligencji w procesie leczenia,
- tworzenie niezależnych i reprezentatywnych zbiorów danych - obecne zbiory są ograniczone i stronnicze, szczególnie pod względem płci, fototypów skóry oraz wieku pacjentów,
- poufność danych - zapewnienie bezpiecznej integracji zanonimizowanych danych pochodzących z wielu źródeł.

W wyniku powszechności urządzeń mobilnych medycyna stopniowo przenosi się do wymiaru cyfrowego i internetowego Integracja usług zdrowotnych z aplikacjami mobilnymi może znacząco zwiększyć dostępność opieki, poprawić profilaktykę oraz umożliwić pacjentom bardziej świadome zarządzanie własnym zdrowiem. Rozwijanie narzędzi łączących algorytmy diagnostyczne z intuicyjnymi interfejsami mobilnymi stanowi naturalny kierunek rozwoju współczesnej medycyny cyfrowej (Bourouis i in., 2013; of Computer Science i in., 2020). W niniejszej pracy przedstawiono propozycję systemu integrującego możliwości głębokich sieci neuronowych w diagnostyce zmian skórnych z aplikacją mobilną przeznaczoną dla systemu Android, co stanowi przykład praktycznego wykorzystania głebokiego uczenia w nowoczesnej opiece zdrowotnej.

Rozdział 3

Propozycja systemu do diagnostyki zmian skórnych

3.1 Dostępne zbiory danych zmian skórnych

Do rozwoju metod sztucznej inteligencji w dermatologii w istotny sposób przyczyniła się organizacja International Skin Imaging Collaboration (ISIC), której celem jest zwiększenie skuteczności wczesnego wykrywania czerniaka i tym samym zmniejszenie śmiertelności związanej z nowotworami skóry. Od 2016 roku ISIC udostępnia obszerne zbiory obrazów z badań dermoskopowych wraz z danymi klinicznymi i wynikami diagnoz, organizując coroczne konkursy mające na celu doskonalenie algorytmów wizji komputerowej. Archiwa ISIC odegrały kluczową rolę w rozwoju badań nad wykorzystaniem sztucznej inteligencji w diagnostyce nowotworów skóry, a opracowane przez organizację standardy są powszechnie akceptowane w dziedzinie CADx (Li i in., 2022).

3.1.1 Dobór zbiorów i opis zmian skórnych

3.2 Infrastruktura

3.3 Zastosowanie

3.4 Podsumowanie

Rozdział 4

Metodyka badania

4.1 Wstęp

4.2 Obróbka danych

4.3 Przygotowanie modelu do trenowania

4.4 Trenowanie modelu

4.5 Podsumowanie

Rozdział 5

Wyniki i wnioski

5.1 Podsumowanie

o co mozna polepszyc prace: - system dostepny tylko na android - rozszerzenie o inne systemy - uwzglednienie danych o pacjencie takich jak wiek, plec, lokalizacja zmiany itd - usuwanie wlosow z zdjec - segmentacja ROI (?) - trenowanie tylko na zdjeciach z telefonu - nie mozna okreslic rozmiaru zmiany - nie mozna porownac zmiany z innymi zmianami pacjenta - grad-CAM - gradient-based localization

Rozdział 6

Podsumowanie

Bibliografia

Abbasi, N. R., Shaw, H. M., Rigel, D. S., Friedman, R. J., McCarthy, W. H., Osman, I., Kopf, A. W., Polsky, D. (2004). Early Diagnosis of Cutaneous Melanoma: Revisiting the ABCD Criteria. *JAMA*, *292*(22), 2771. https://doi.org/10.1001/jama.292.22.2771

Adegun, A. A., Viriri, S. (2020). Deep Learning-Based System for Automatic Melanoma Detection. *IEEE Access*, *8*, 7160–7172. https://doi.org/10.1109/ACCESS.2019.2962812

Ali, S., Abuhmed, T., El-Sappagh, S., Muhammad, K., Alonso-Moral, J. M., Confalonieri, R., Guidotti, R., Del Ser, J., Díaz-Rodríguez, N., Herrera, F. (2023). Explainable Artificial Intelligence (XAI): What we know and what is left to attain Trustworthy Artificial Intelligence. *Information Fusion*, *99*, 101805. https://doi.org/10.1016/j.inffus.2023.101805

Alonso, S. G., De La Torre Díez, I., Zapiraín, B. G. (2019). Predictive, Personalized, Preventive and Participatory (4P) Medicine Applied to Telemedicine and eHealth in the Literature. *Journal of Medical Systems*, *43*(5), 140. https://doi.org/10.1007/s10916-019-1279-4

Al-rimy, B. A. S., Saeed, F., Al-Sarem, M., Albarrak, A. M., Qasem, S. N. (2023). An Adaptive Early Stopping Technique for DenseNet169-Based Knee Osteoarthritis Detection Model. *Diagnostics*, *13*(11), 1903. https://doi.org/10.3390/diagnostics13111903

Alwakid, G., Gouda, W., Humayun, M., Sama, N. U. (2022). Melanoma Detection Using Deep Learning-Based Classifications. *Healthcare*, *10*(12), 2481. https://doi.org/10.3390/healthcare10122481

Alzubaidi, L., Al-Amidie, M., Al-Asadi, A., Humaidi, A. J., Al-Shamma, O., Fadhel, M. A., Zhang, J., Santamaría, J., Duan, Y. (2021). Novel Transfer Learning Approach for

Medical Imaging with Limited Labeled Data. *Cancers*, *13*(7), 1590. https://doi.org/10.3390/cancers13071590

Amisha, Malik, P., Pathania, M., Rathaur, V. (2019). Overview of artificial intelligence in medicine. *Journal of Family Medicine and Primary Care*, *8*(7), 2328. https://doi.org/10.4103/jfmpc.jfmpc_440_19

Bassel, A., Abdulkareem, A. B., Alyasseri, Z. A. A., Sani, N. S., Mohammed, H. J. (2022). Automatic Malignant and Benign Skin Cancer Classification Using a Hybrid Deep Learning Approach. *Diagnostics*, *12*(10). https://doi.org/10.3390/diagnostics12102472

Bourouis, A., Zerdazi, A., Feham, M., Bouchachia, A. (2013). M-Health: Skin Disease Analysis System Using Smartphone's Camera. *Procedia Computer Science*, *19*, 1116–1120. https://doi.org/10.1016/j.procs.2013.06.157

Briganti, G., Le Moine, O. (2020). Artificial Intelligence in Medicine: Today and Tomorrow. *Frontiers in Medicine*, *7*, 27. https://doi.org/10.3389/fmed.2020.00027

Chapman, T., Larsson, E., von Wrycza, P., Dahlman, E., Parkvall, S., Sköld, J. (2015). Chapter 1 - From 3G to 4G: background and motivation of 3G evolution. W T. Chapman, E. Larsson, P. von Wrycza, E. Dahlman, S. Parkvall J. Sköld (Red.), *HSPA Evolution* (s. 3–20). Academic Press. https://doi.org/https://doi.org/10.1016/B978-0-08-099969-2.00001-6

Congdon, N. M., Davis, C. M. (2023). A systematic review of the frequency of features of the seven-point checklist in proven cutaneous melanoma: The importance of change. *Skin Health and Disease*, *3*(6), e295. https://doi.org/10.1002/ski2.295

Dai, X., Spasić, I., Meyer, B., Chapman, S., Andres, F. (2019). Machine Learning on Mobile: An On-device Inference App for Skin Cancer Detection. *2019 Fourth International Conference on Fog and Mobile Edge Computing (FMEC)*, 301–305. https://doi.org/10.1109/FMEC.2019.8795362

Das, N., Happaerts, S., Gyselinck, I., Staes, M., Derom, E., Brusselle, G., Burgos, F., Contoli, M., Dinh-Xuan, A. T., Franssen, F. M., Gonem, S., Greening, N., Haenebalcke, C., Man, W. D.-C., Moisés, J., Peché, R., Poberezhets, V., Quint, J. K., Steiner, M. C., Vanderhelst, E., Abdo, M., Topalovic, M., Janssens, W. (2023). Collaboration between explainable artificial intelligence and pulmonologists improves the

accuracy of pulmonary function test interpretation. *European Respiratory Journal*, *61*(5), 2201720. https://doi.org/10.1183/13993003.01720-2022

Davis, S., Piggott, C., Lyon, C., DeSanto, K. (2020). Effectiveness of dermoscopy in skin cancer diagnosis. *Canadian Family Physician Medecin De Famille Canadien*, *66*(10), 739–740.

Duarte, A. F., Sousa-Pinto, B., Azevedo, L. F., Barros, A. M., Puig, S., Malvehy, J., Haneke, E., Correia, O. (2021). Clinical ABCDE rule for early melanoma detection. *European Journal of Dermatology*, *31*(6), 771–778. https://doi.org/10.1684/ejd.2021.4171

Elyan, E., Vuttipittayamongkol, P., Johnston, P., Martin, K., McPherson, K., Moreno-García, C. F., Jayne, C., Sarker, M. M. K. (2022). Computer vision and machine learning for medical image analysis: recent advances, challenges, and way forward. *Artificial Intelligence Surgery*, *2*(1). https://doi.org/10.20517/ais.2021.15

Erickson, B. J., Kitamura, F. (2021). Magician's Corner: 9. Performance Metrics for Machine Learning Models. *Radiology: Artificial Intelligence*, *3*(3), e200126. https://doi.org/10.1148/ryai.2021200126

Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, *542*(7639), 115–118. https://doi.org/10.1038/nature21056

Farhud, D. D., Zokaei, S. (2021). Ethical Issues of Artificial Intelligence in Medicine and Healthcare. *Iranian Journal of Public Health*, *50*(11), i–v. https://doi.org/10.18502/ijph.v50i11.7600

Ghosh, A., Sufian, A., Sultana, F., Chakrabarti, A., De, D. (2020, styczeń). Fundamental Concepts of Convolutional Neural Network. https://doi.org/10.1007/978-3-030-32644-9_36

Głos, A. (2017). MEDYCYNA P4 I ANTYNOMIE SAMOWIEDZY. *Filozofia w Praktyce*, *Tom 3*(Artykuł 6).

Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning* [http://www.deeplearningbook.org]. MIT Press.

Grandini, M., Bagli, E., Visani, G. (2020). Metrics for Multi-Class Classification: an Overview. https://doi.org/10.48550/ARXIV.2008.05756

Grob, J. J., Bonerandi, J. J. (1998). The 'Ugly Duckling' Sign: Identification of the Common Characteristics of Nevi in an Individual as a Basis for Melanoma Screening. *Archives of Dermatology*, *134*(1), 103. https://doi.org/10.1001/archderm.134.1.103-a

Groh, M., Harris, C., Soenksen, L., Lau, F., Han, R., Kim, A., Koochek, A., Badri, O. (2021). Evaluating deep neural networks trained on clinical images in dermatology with the fitzpatrick 17k dataset. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 1820–1828.

Gutkowicz-Krusin, D., Elbaum, M., Jacobs, A., Keem, S., Kopf, A. W., Kamino, H., Wang, S., Rubin, P., Rabinovitz, H., Oliviero, M. (2000). Precision of automatic measurements of pigmented skin lesion parameters with a MelaFindTM multispectral digital dermoscope: *Melanoma Research*, *10*(6), 563–570. https://doi.org/10.1097/00008390-200012000-00008

Halcox, J. P., Wareham, K., Cardew, A., Gilmore, M., Barry, J. P., Phillips, C., Gravenor, M. B. (2017). Assessment of Remote Heart Rhythm Sampling Using the AliveCor Heart Monitor to Screen for Atrial Fibrillation: The REHEARSE-AF Study. *Circulation*, *136*(19), 1784–1794. https://doi.org/10.1161/CIRCULATIONAHA.117.030583

Haleem, A., Javaid, M., Singh, R. P., Rab, S., Suman, R. (2023). Applications of nanotechnology in medical field: a brief review. *Global Health Journal*, *7*(2), 70–77. https://doi.org/https://doi.org/10.1016/j.glohj.2023.02.008

Han, S. S., Kim, M. S., Lim, W., Park, G. H., Park, I., Chang, S. E. (2018). Classification of the Clinical Images for Benign and Malignant Cutaneous Tumors Using a Deep Learning Algorithm. *Journal of Investigative Dermatology*, *138*(7), 1529–1538. https://doi.org/10.1016/j.jid.2018.01.028

He, J., Baxter, S. L., Xu, J., Xu, J., Zhou, X., Zhang, K. (2019). The practical implementation of artificial intelligence technologies in medicine. *Nature Medicine*, *25*(1), 30–36. https://doi.org/10.1038/s41591-018-0307-0

Henning, J. S., Stein, J. A., Yeung, J., Dusza, S. W., Marghoob, A. A., Rabinovitz, H. S., Polsky, D., Kopf, A. W. (2008). CASH Algorithm for Dermoscopy Revisited. *Archives of Dermatology*, *144*(4). https://doi.org/10.1001/archderm.144.4.554

Hinton, G., Krizhevsky, A., Sutskever, I., Rachmad, Y. (2012). ImageNet Classification with Deep Convolutional Neural Networks. *Advances in Neural Information Processing Systems*, 1097–1105. https://doi.org/10.1145/3065386

Hosseinzadeh Kassani, S., Hosseinzadeh Kassani, P. (2019). A comparative study of deep learning architectures on melanoma detection. *Tissue and Cell*, *58*, 76–83. https://doi.org/10.1016/j.tice.2019.04.009

Hubel, D. H., Wiesel, T. N. (1968). Receptive fields and functional architecture of monkey striate cortex. *The Journal of Physiology*, *195*(1), 215–243. https://doi.org/10.1113/jphysiol.1968.sp008455

Hussain, E., Hasan, M., Rahman, M. A., Lee, I., Tamanna, T., Parvez, M. Z. (2021). CoroDet: A deep learning based classification for COVID-19 detection using chest X-ray images. *Chaos, Solitons & Fractals*, *142*, 110495. https://doi.org/10.1016/j.chaos.2020.110495

Ismael, A. M., Şengür, A. (2021). Deep learning approaches for COVID-19 detection based on chest X-ray images. *Expert Systems with Applications*, *164*, 114054. https://doi.org/10.1016/j.eswa.2020.114054

Jojoa Acosta, M. F., Caballero Tovar, L. Y., Garcia-Zapirain, M. B., Percybrooks, W. S. (2021). Melanoma diagnosis using deep learning techniques on dermatoscopic images. *BMC Medical Imaging*, *21*(1), 6. https://doi.org/10.1186/s12880-020-00534-8

Kaminska-Winciorek, G., Spiewak, R. (2011). [Basic dermoscopy of melanocytic lesions for beginners]. *Postępy higieny i medycyny doświadczalnej (Online)*, *65*, 501–8. https://doi.org/10.5604/17322693.955121

Kawahara, J., Bentaieb, A., Hamarneh, G. (2016). Deep features to classify skin lesions, 1397–1400. https://doi.org/10.1109/ISBI.2016.7493528

Kelly, C. J., Karthikesalingam, A., Suleyman, M., Corrado, G., King, D. (2019). Key challenges for delivering clinical impact with artificial intelligence. *BMC Medicine*, *17*(1), 195. https://doi.org/10.1186/s12916-019-1426-2

Kong, F. W., Horsham, C., Ngoo, A., Soyer, H. P., Janda, M. (2021). Review of smartphone mobile applications for skin cancer detection: what are the changes in availability, functionality, and costs to users over time? *International Journal of Dermatology*, *60*(3), 289–308. https://doi.org/10.1111/ijd.15132

Kousis, I., Perikos, I., Hatzilygeroudis, I., Virvou, M. (2022). Deep Learning Methods for Accurate Skin Cancer Recognition and Mobile Application. *Electronics*, *11*(9), 1294. https://doi.org/10.3390/electronics11091294

LeCun, Y., Bengio, Y., Hinton, G. (2015). Deep learning. *Nature*, *521*(7553), 436–444. https://doi.org/10.1038/nature14539

Lee, K. H., Lee, R. W., Kwon, Y. E. (2023). Validation of a Deep Learning Chest X-ray Interpretation Model: Integrating Large-Scale AI and Large Language Models for Comparative Analysis with ChatGPT. *Diagnostics*, *14*(1), 90. https://doi.org/10.3390/diagnostics14010090

Li, Z., Koban, K. C., Schenck, T. L., Giunta, R. E., Li, Q., Sun, Y. (2022). Artificial Intelligence in Dermatology Image Analysis: Current Developments and Future Trends. *Journal of Clinical Medicine*, *11*(22), 6826. https://doi.org/10.3390/jcm11226826

Lu, X., Firoozeh Abolhasani Zadeh, Y. A. (2022). Deep Learning-Based Classification for Melanoma Detection Using XceptionNet (S. Jafarzadeh Ghoushchi, Red.). *Journal of Healthcare Engineering*, *2022*, 1–10. https://doi.org/10.1155/2022/2196096

MacKie, R. M. (1990). Clinical recognition of early invasive malignant melanoma. *BMJ (Clinical research ed.)*, *301*(6759), 1005–1006. https://doi.org/10.1136/bmj.301.6759.1005

Mackie, R. M. (1989). *Malignant melanoma: a guide to early diagnosis*. Duphar Laboratories.

Mahara, G., Tian, C., Xu, X., Wang, W. (2023). Revolutionising health care: Exploring the latest advances in medical sciences. *Journal of Global Health*, *13*, 03042. https://doi.org/10.7189/jogh.13.03042

Mahbod, A., Schaefer, G., Wang, C., Dorffner, G., Ecker, R., Ellinger, I. (2020). Transfer learning using a multi-scale and multi-network ensemble for skin lesion classification. *Computer Methods and Programs in Biomedicine*, *193*, 105475. https://doi.org/10.1016/j.cmpb.2020.105475

Menegola, A., Fornaciali, M., Pires, R., Bittencourt, F. V., Avila, S., Valle, E. (2017). Knowledge Transfer for Melanoma Screening with Deep Learning [arXiv:1703.07479], (arXiv:1703.07479). https://doi.org/10.48550/arXiv.1703.07479

Menzies, S. W., Ingvar, C., Crotty, K. A., McCarthy, W. H. (1996). Frequency and morphologic characteristics of invasive melanomas lacking specific surface microscopic features. *Archives of Dermatology*, *132*(10), 1178–1182.

Nachbar, F., Stolz, W., Merkle, T., Cognetta, A. B., Vogt, T., Landthaler, M., Bilek, P., Braun-Falco, O., Plewig, G. (1994). The ABCD rule of dermatoscopy. *Journal of the American Academy of Dermatology*, *30*(4), 551–559. https://doi.org/10.1016/S0190-9622(94)70061-3

Naeem, A., Farooq, M. S., Khelifi, A., Abid, A. (2020). Malignant Melanoma Classification Using Deep Learning: Datasets, Performance Measurements, Challenges and Opportunities. *IEEE Access*, *8*, 110575–110597. https://doi.org/10.1109/ACCESS.2020.3001507

Nayak, S., Kumar Das, R. (2020, listopad). Application of Artificial Intelligence (AI) in Prosthetic and Orthotic Rehabilitation. W V. Sezer, S. Öncü P. Boyraz Baykas (Red.), *Service Robotics*. IntechOpen. https://doi.org/10.5772/intechopen.93903

of Computer Science, D., Engineering, O., Ladoke Akintola University of Technology, O. Emuoyibofarhe, J., Ajisafe, D. (2020). Early Skin Cancer Detection Using Deep Convolutional Neural Networks on Mobile Smartphone. *International Journal of Information Engineering and Electronic Business*, *12*(2), 21–27. https://doi.org/10.5815/ijieeb.2020.02.04

Rainio, O., Teuho, J., Klén, R. (2024). Evaluation metrics and statistical tests for machine learning. *Scientific Reports*, *14*(1), 6086. https://doi.org/10.1038/s41598-024-56706-x

Rajaraman, S., Antani, S. K., Poostchi, M., Silamut, K., Hossain, M. A., Maude, R. J., Jaeger, S., Thoma, G. R. (2018). Pre-trained convolutional neural networks as feature extractors toward improved malaria parasite detection in thin blood smear images. *PeerJ*, *6*, e4568. https://doi.org/10.7717/peerj.4568

Rajaraman, S., Candemir, S., Kim, I., Thoma, G., Antani, S. (2018). Visualization and Interpretation of Convolutional Neural Network Predictions in Detecting Pneumonia in Pediatric Chest Radiographs. *Applied Sciences (Basel, Switzerland)*, *8*(10), 1715. https://doi.org/10.3390/app8101715

Richens, J. G., Buchard, A. (2021). Artificial Intelligence for Medical Diagnosis. W N. Lidströmer H. Ashrafian (Red.), *Artificial Intelligence in Medicine* (s. 1–21). Springer

International Publishing. https://doi.org/10.1007/978-3-030-58080-3_29-1

Rogers, T., Marino, M., Dusza, S. W., Bajaj, S., Marchetti, M. A., Marghoob, A. (2017). Triage amalgamated dermoscopic algorithm (TADA) for skin cancer screening. *Dermatology Practical & Conceptual*, *7*(2), 39–46. https://doi.org/10.5826/dpc.0702a09

Rosendahl, C., Cameron, A., McColl, I., Wilkinson, D. (2012). Dermatoscopy in routine practice - "chaos and clues". *Australian Family Physician*, *41*(7), 482–487.

Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2016/679 z dnia 27 kwietnia 2016 r. w sprawie ochrony osób fizycznych w związku z przetwarzaniem danych osobowych i w sprawie swobodnego przepływu takich danych (RODO) [General Data Protection Regulation (GDPR)]. (2016). https://eur-lex.europa.eu/eli/reg/2016/679/oj

Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2024/1689 z dnia 13 czerwca 2024 r. ustanawiające zharmonizowane przepisy dotyczące sztucznej inteligencji (Akt o sztucznej inteligencji) [Artificial Intelligence Act (AI Act)]. (2024). https://eur-lex.europa.eu/eli/reg/2024/1689/oj

Russell, S. J., Norvig, P. (2022). *Artificial intelligence: a modern approach* (Fourth edition, global edition). Pearson.

Rutkowski, P., J. Wysocki, P., Nasierowska-Guttmejer, A., Fijuth, J., Kalinka-Warzocha, E., Świtaj, T., Jeziorski, A., Szacht, M., Zegarski, W., Wysocki, W. M., Rudnicka, L., Owczarek, W., Krzakowski, M. (2016). Cutaneous melanoma – guidelines for diagnostics and therapy in 2016. *Dermatology Review*, *1*, 1–18. https://doi.org/10.5114/dr.2016.57736

Sonthalia, S., Yumeen, S., Kaliyadan, F. (2025). Dermoscopy Overview and Extradiagnostic Applications. W *StatPearls*. StatPearls Publishing. http://www.ncbi.nlm.nih.gov/books/NBK537131/

Tang, L., Li, J., Fantus, S. (2023). Medical artificial intelligence ethics: A systematic review of empirical studies. *DIGITAL HEALTH*, *9*, 20552076231186064. https://doi.org/10.1177/20552076231186064

Thacharodi, A., Singh, P., Meenatchi, R., Tawfeeq Ahmed, Z. H., Kumar, R. R. S., V, N., Kavish, S., Maqbool, M., Hassan, S. (2024). Revolutionizing healthcare and medi-

cine: The impact of modern technologies for a healthier future—A comprehensive review. *Health Care Science*, *3*(5), 329–349. https://doi.org/10.1002/hcs2.115

Topalovic, M., Das, N., Burgel, P.-R., Daenen, M., Derom, E., Haenebalcke, C., Janssen, R., Kerstjens, H. A., Liistro, G., Louis, R., Ninane, V., Pison, C., Schlesser, M., Vercauter, P., Vogelmeier, C. F., Wouters, E., Wynants, J., Janssens, W. (2019). Artificial intelligence outperforms pulmonologists in the interpretation of pulmonary function tests. *European Respiratory Journal*, *53*(4), 1801660. https://doi.org/10.1183/13993003.01660-2018

Van Kolfschooten, H., Van Oirschot, J. (2024). The EU Artificial Intelligence Act (2024): Implications for healthcare. *Health Policy*, *149*, 105152. https://doi.org/10.1016/j.healthpol.2024.105152

Walter, F. M., Prevost, A. T., Vasconcelos, J., Hall, P. N., Burrows, N. P., Morris, H. C., Kinmonth, A. L., Emery, J. D. (2013). Using the 7-point checklist as a diagnostic aid for pigmented skin lesions in general practice: a diagnostic validation study. *The British Journal of General Practice: The Journal of the Royal College of General Practitioners*, *63*(610), e345–353. https://doi.org/10.3399/bjgp13X667213

Ward-Peterson, M., Acuña, J. M., Alkhalifah, M. K., Nasiri, A. M., Al-Akeel, E. S., Alkhaldi, T. M., Dawari, S. A., Aldaham, S. A. (2016). Association Between Race/Ethnicity and Survival of Melanoma Patients in the United States Over 3 Decades: A Secondary Analysis of SEER Data. *Medicine*, *95*(17), e3315. https://doi.org/10.1097/MD.0000000000003315

Wibowo, A., Adhi Hartanto, C., Wisnu Wirawan, P. (2020). Android skin cancer detection and classification based on MobileNet v2 model. *International Journal of Advances in Intelligent Informatics*, *6*(2), 135. https://doi.org/10.26555/ijain.v6i2.492

Yang, Y. J., Bang, C. S. (2019). Application of artificial intelligence in gastroenterology. *World Journal of Gastroenterology*, *25*(14), 1666–1683. https://doi.org/10.3748/wjg.v25.i14.1666

Yélamos, O., Braun, R. P., Liopyris, K., Wolner, Z. J., Kerl, K., Gerami, P., Marghoob, A. A. (2019). Usefulness of dermoscopy to improve the clinical and histopathologic dia-

gnosis of skin cancers. *Journal of the American Academy of Dermatology*, *80*(2), 365–377. https://doi.org/10.1016/j.jaad.2018.07.072

Spis tabel

2.1 Algorytm ABCD 5

Spis rysunków

2.1 Relacje między sztuczną inteligencją, uczeniem maszynowym i głębokim uczeniem 8
2.2 Podstawowa architektura konwolucyjnej sieci neuronowej 9
2.3 Przykładowa macierz pomyłek z pracy 11

Spis kodów źródłowych